

人工智能

基于大模型智能体的代码分析与评测系统研究与应用

陈玲

(泸州职业技术学院, 四川泸州 646000)

摘 要: 针对传统编程教学中的反馈滞后、评价主观、个性化不足等问题, 本文提出了一种基于大语言模型智能体的代码分析与评测系统。系统通过多智能体协作实现了代码智能分析、错误诊断、改进建议生成和自动评分等功能。通过提示词工程设计了基于评分点的智能评阅机制, 能够自动完成期末考试等编程作业的评分工作。该系统代码错误检测准确率达到 96.8%, 自动评分与人工评分的一致性达到 94.2%, 显著提升了编程教学效率和质量。

关键词: 大语言模型; 智能体; 编程教学; 自动评分; 代码分析

中图分类号: TP277

文献标识码: A

DOI: 10.3969/j.issn.1003-6970.2025.06.011

本文著录格式: 陈玲. 基于大模型智能体的代码分析与评测系统研究与应用[J]. 软件, 2025, 46(6): 043-047+174

Research and Application of Code Analysis and Evaluation System Based on Large Language Model Agents

CHEN Ling

(Luzhou Vocational & Technical College, Luzhou Sichuan 646000)

【Abstract】: To address the problems of delayed feedback, subjective evaluation, and insufficient personalization in traditional programming education, a code analysis and evaluation system based on large language model agents is proposed. The system implements intelligent code analysis, error diagnosis, improvement suggestion generation, and automatic scoring through multi-agent collaboration. An intelligent grading mechanism based on scoring points is designed through prompt engineering, which can automatically complete the scoring of programming assignments such as final exams. The system achieves 96.8% accuracy in code error detection and 94.2% consistency between automatic scoring and manual scoring, significantly improving the efficiency and quality of programming education.

【Key words】: large language model; agent; programming education; automatic scoring; code analysis

0 引言

代码编写是计算机类专业教育的核心环节, 然而, 传统教学模式面临诸多挑战, 如教师批改代码工作量大、反馈不及时、难以提供个性化指导等。特别是在期末考试等大规模编程作业评阅中, 人工评分不仅耗时耗力, 而且存在主观性强、一致性差等问题。

近年来, 大语言模型在代码理解和生成方面展现出了强大的能力, 为编程教学提供了新的技术路径^[1]。GitHub Copilot、MarsCode 等工具的成功应用证明了 AI 在代码生成方面的潜力, 但现有工具主要面向专业开发者, 缺乏针对教育场景的深度定制。

本文提出了一种基于大模型智能体的代码分析与评

估系统, 通过多智能体协作实现代码分析、错误诊断和自动评分等功能。系统的主要贡献如下: (1) 设计了多智能体协作架构, 实现了编程教学全流程的智能化辅助; (2) 提出了基于评分点的自动评阅机制, 显著提升了评分效率和一致性; (3) 通过实际部署验证了系统的有效性和实用性。

1 相关工作

1.1 代码分析与评估技术

传统代码自动评分主要依赖在线判题系统 (OJ), 如 POJ、HOJ、蓝桥云课等平台通过预设测试用例进行自动评判。这种评分方式虽然能够处理大规模提交, 但存在评判机制单一、反馈信息有限等问题。近年来, 一

作者简介: 陈玲 (1983—), 女, 硕士, 副教授, 研究方向: 软件开发、人工智能技术。

些研究尝试引入机器学习技术改进编程教学,如基于静态分析的代码质量评估、基于聚类的错误模式识别等,但整体智能化程度仍然有限。

1.2 代码生成大模型

以 Claude3.7、Gemini 2.5^[2] 为代表的大模型在代码相关任务上取得了突破性进展。GitHub Copilot 实现了高质量的代码生成, Claude 在多种编程语言上表现出色。然而,这些模型主要面向专业开发场景,在教育应用方面存在直接给出答案、缺乏教学适应性问题。

1.3 智能体技术

多智能体系统通过协作完成复杂任务的能力为编程教学提供了新思路。ReAct、AutoGPT 等框架展示了智能体在复杂推理和工具使用方面的潜力。本文将智能体技术引入代码分析和自动评估,通过专门设计的智能体实现教学任务的自动化处理。

2 系统架构设计

2.1 总体架构

系统采用基于 Dify 平台的多智能体协作架构,构建了一个完整的代码分析与评测生态系统。系统核心包含四个专门化的智能体和一个统一的协调 workflow: 代码分析智能体负责代码的静态分析,包括语法检查、代码风格评估、复杂度分析等基础分析任务; 错误诊断智能体专门用于错误检测和分类,能够识别语法错误、逻辑错误、运行时异常等多种类型的代码问题; 建议生成智能体基于前两个智能体的分析和诊断结果,生成针对性的改进建议和学习指导,为学生提供个性化的学习反馈; 评分智能体根据预设的评分标准对编程作业进行自动评分,确保评价的客观性和一致性。四个智能体通过基于 Dify 的工作流引擎进行统一协调,协调层负责智能体间的任务分配、结果聚合和冲突解决,确保整个系




图 1 基于大模型智能体的代码分析与评估系统架构图

Fig.1 Architecture diagram of code analysis and evaluation system based on large language model agents

统能够高效、稳定地运行,实现从代码提交到评估反馈的全流程自动化处理。如图 1 所示。

2.2 基于 Dify 的智能体开发平台

选择 Dify 作为智能体开发平台,主要基于以下几个方面的考虑。(1) Dify 提供了直观的可视化界面,支持拖拽式的工作流设计,便于构建复杂的多智能体协作流程,大大降低了系统开发的技术门槛。(2) 该平台具备多模型集成能力,支持多种大语言模型的集成,使得系统能够为不同智能体选择最适合的模型,实现功能的最优化配置。(3) Dify 支持企业级部署,能够满足教育机构对数据安全和隐私保护的严格要求,这对于处理学生作业和考试数据尤为重要。

2.3 Dify 智能体协作机制

基于 Dify 平台设计的智能体协作流程采用分阶段处理模式,整个代码评阅 workflow 包含六个关键步骤。(1) 输入。输入节点负责接收学生提交的代码、题目要求、评分标准等。(2) 并行分析处理。代码分析智能体和错误诊断智能体同时工作,分别负责代码质量分析和错误检测,这种并行处理机制显著提升了系统效率。(3) 建议生成。由建议生成智能体参考前两个智能体的分析结果,生成针对性的改进建议。(4) 智能评分。评分智能体根据预设标准并参考代码分析报告和错误监测报告进行自动评分。(5) 综合报告智能体负责整合所有分析结果,生成完整的评估报告。(6) 结果输出。将评估结果返回给用户,形成完整的闭环处理流程。

3 关键技术实现

3.1 代码分析智能体 Code Analysis Agent

核心功能:对代码进行静态分析,评估代码质量,如语法、风格、结构、复杂度等。

关键输入: {{student_code}} (学生提交的代码), {{language}} (编程语言), (可选) {{coding_standards_rules}} (代码规范细则)。

关键输出: JSON 对象,包含代码语法分析结果、结构评估、命名规范检查、可读性与维护性评价等。

提示词:

角色: "你是一名专业的编程教师及代码审查专家,精通 {{language}} 语言。"

指令:

"仔细分析以下由学生提交的 {{language}} 代码: \n{{student_code}}"

"重点评估以下方面: 1. 代码语法的正确性。2. 程序结构的合理性(例如模块化、函数划分)。3. 变量、函数命名的规范性和表意清晰度。4. 代码的可读性和可

维护性（例如注释、代码缩进、一致性）。5.（可选）代码复杂度初步评估。"

"考虑到这是职业教育场景，分析应侧重于代码的工程实践价值和基本规范，避免对算法效率进行过度深入的探讨，除非其严重影响功能。"

输出格式：

"请将你的分析结果以JSON格式返回。JSON对象应包含键：syntax_check（布尔值或详细信息），structure_evaluation（文本描述及评分1-5），naming_conventions（文本描述及符合度），readability_maintenance（文本描述及评分1-5），complexity_assessment（初步意见）。"

3.2 错误诊断智能体 Error Diagnosis Agent

核心功能：专门用于检测和分类代码中的错误，如语法错误、逻辑错误、潜在的运行时异常。

关键输入：{{student_code}}, {{language}},（可选）{{common_student_errors_knowledge_base}}（常见学生错误知识库）。

关键输出：JSON对象，包含错误列表，每个错误包含类型、定位（行号）、错误描述、可能原因。

提示词：

角色："你是一位经验丰富的{{language}}语言调试专家和编程导师，擅长快速定位并解释学生代码中的各种错误。"

指令：

"请诊断以下学生提交的{{language}}代码中的错误：\n{{student_code}}"

"识别并列出所有检测到的错误，包括但不限于：1. 语法错误。2. 明显的逻辑错误。3. 可能导致运行时异常的代码片段（例如除零、空指针、数组越界等）。"

"对每个错误，请提供：错误类型（如语法错误、逻辑错误、潜在风险）、错误发生的具体行号（如果可能）、对错误的简明描述，以及对初学者而言易于理解的可能原因分析。"

输出格式：

"请将诊断结果以JSON格式返回。顶层是一个名为errors的数组，数组中每个元素是一个对象，包含键：error_type, line_number, error_description, possible_cause。"

3.3 建议生成智能体 Suggestion Generation Agent

核心功能：基于代码分析和错误诊断的结果，生成具体的、有针对性的改进建议和学习指导。

关键输入：{{student_code}}, {{analysis_report}}（代码分析智能体的输出），{{diagnosis_report}}（错误

诊断智能体的输出）。

关键输出：JSON对象，包含针对性的改进建议列表，每个建议包含问题点、建议内容、学习资源链接（可选）。

提示词：

角色："你是一位富有同理心和教学技巧的编程辅导老师。"

指令：

"参考以下学生代码：\n{{student_code}}"

"以及对其的代码分析报告：\n{{analysis_report}}"

"和错误诊断报告：\n{{diagnosis_report}}"

"你的任务是针对上述报告中指出的问题和不足，为学生提供清晰、具体、可操作的改进建议。"

"建议应具有建设性，帮助学生理解问题本质并掌握正确的编程方法。"

"针对每个主要问题点，生成1-2条核心改进建议。如果适用，可以引导学生思考，而非直接给出修改后的代码。"

"保持积极和鼓励的语气。"

输出格式：

"请将改进建议以JSON格式返回。顶层是一个名为suggestions的数组，每个元素是一个对象，包含键：problem_area（如'代码结构'、'变量命名'、'特定逻辑错误'），suggestion_text, learning_resource_link（可选）。"

3.4 评分智能体 Scoring Agent

核心功能：根据预设的评分标准（评分点）和作业要求，对编程作业进行自动评分，并给出每个评分点的得分和反馈。

关键输入：{{student_code}}（学生提交的代码），{{assignment_requirements}}（作业要求），{{scoring_rubric}}（包含详细评分点、各点分值、评分标准的JSON对象或结构化文本），（可选）{{analysis_report}}（代码分析报告），{{diagnosis_report}}（错误诊断报告）。

关键输出：JSON对象，包含总分、各主要维度得分（如功能实现、代码规范、代码质量）、每个细分评分点的得分、理由和简短反馈。

提示词：

角色："你是一位经验丰富的编程课教师，负责根据明确的评分标准评阅学生的编程作业。"

指令：

"以下是学生的作业要求：\n{{assignment_requirements}}"

" 以下是本次作业的详细评分标准和各评分点：
\n{{scoring_rubric}}"

" 以下是学生提交的代码：\n{{student_code}}"

"(可选) 参考代码分析报告：\n{{analysis_report}}"

"(可选) 参考错误诊断报告：\n{{diagnosis_report}}"

" 请严格按照提供的评分标准和评分点，对学生的代码进行打分。"

" 对于评分标准中的每一个评分点，请给出具体得分，并简要说明得分或扣分的原因。"

" 重点评估功能实现情况，同时兼顾代码规范和质量，但要符合职业教育的实用性导向。"

输出格式：

" 请将评分结果以 JSON 格式输出。JSON 对象必须包含以下键：total_score (数字), functionality_score (数字), standards_score (数字), quality_score (数字), detailed_feedback (一个对象，键为评分点名称，值为包含 score_achieved, max_score, feedback_text 的对象), overall_comment (可选的总体评语)。"

3.5 多智能体整合工作流

多智能体整体工作流如图 2 所示，工作流通过 Dify 平台的工作流引擎实现智能体间的任务调度和数据传递。工作流采用流水线处理模式，确保各智能体按照预设顺序执行任务，同时支持并行处理以提升整体效率，并将最终结果进行统一格式化输出。

3.6 在线编程环境集成

为了实现智能体评分系统与教学环境的无缝衔接，本研究基于开源 WebIDE 进行了深度二次开发，构建了完整的集成解决方案。使用 Dify 提供的智能体 API 接口，通过接口提交到 Dify 智能体进行评分，学生无需离开编程环境即可获得即时反馈。作业提交接口采用

了标准化的 API 设计，确保代码在传输过程中的安全性和结果返回的可靠性，同时支持批量处理和异步处理模式。在用户界面优化方面，在 IDE 界面中集成了评分结果展示面板，提供多维度的可视化反馈，包括功能实现情况、代码质量指标和改进建议等。系统还增加了版本控制功能，支持作业提交历史记录和版本对比，便于教师跟踪学生的编程进展和学习轨迹，为个性化教学提供数据支撑。

4 应用案例

4.1 期末考试自动评阅

本系统在期末考试自动评阅中得到了全面验证，成功处理了 400 余份编程试卷的评阅工作。考试采用在线编程形式，设置了学生信息管理系统这一综合性编程题目，考试时长为 2 小时，主要编程语言为 Python，400 余名学生参加考试。评分标准突出功能实现的重要性，同时兼顾代码规范和质量，符合职业教育的实用导向。

从评阅效果来看，系统表现出显著的优势。在效率方面，传统人工评阅需要 3 天时间，而智能评阅仅需 2 小时即可完成，效率提升超过 30 倍。在质量方面，系统与资深教师评分的一致性达到 94.2%，证明了自动评分的准确性和可靠性。更重要的是，系统评分具有良好的稳定性，有效消除了人工评分中常见的疲劳效应和主观偏见问题，确保了评分的公平性。从用户接受度来看，92% 的学生认为自动评分公平客观，96% 的教师认为评分结果准确可信，表明系统获得了良好的用户认可。

4.2 典型评分案例

为了更好地展示系统的实际应用效果，选取了一个典型的评分案例进行详细分析。该案例来源于考试中的一道综合编程题，要求学生编写一个简单的学生成绩管理系统。具体功能要求如下：学生信息管理功能需要实




图 2 协调层工作流

Fig.2 Coordination layer workflow

现添加学生信息（学号、姓名、年龄）、删除学生信息、修改学生信息和查看所有学生信息；成绩管理功能需要为学生添加成绩（语文、数学、英语）、修改学生成绩、查看单个学生的成绩以及计算学生总分和平均分；统计功能要求显示全班学生成绩排名（按总分降序）、计算全班各科平均分、统计及格人数（分数 ≥ 60 ）；文件操作功能需要将学生信息和成绩保存到文件（可选择txt或json格式），并从文件中读取学生信息和成绩；用户界面功能要求提供简单的菜单界面供用户选择不同操作，输入数据时提供适当的提示信息，并对异常输入进行基本的错误处理。

学生在 WebIDE 中提交的代码（部分）如下：

```
class Student:
    def __init__(self, student_id, name, age):
        self.student_id = student_id
        self.name = name
        self.age = age
        self.scores = {} # 存储成绩的字典
    def add_score(self, subject, score):
        self.scores[subject] = score
    def get_total_score(self):
        return sum(self.scores.values())
    def get_average_score(self):
        if len(self.scores) == 0:
```

```
        return 0
    return self.get_total_score() / len(self.scores)
    def __str__(self):
        return f"学号: {self.student_id}, 姓名: {self.name},
        年龄: {self.age}"
# 学生管理系统类
class StudentManager:
    def __init__(self):
        self.students = [] # 存储所有学生的列表
        以下代码省略 .....
        通过 API 提交到智能体后的评分结果如图 3 所示。
        智能体输出的改进建议：
        改进建议：
        (1) 输入验证优化。
        问题：菜单和成绩输入验证可加强。
        建议：创建独立的 validate_score() 方法处理分数
        验证，并通过循环实现重试机制。
        (2) 代码复用提升。
        问题：多处重复查找学生逻辑。
        建议：严格遵循 DRY 原则，统一使用 find_student()
        方法，使代码更易维护。
        (3) 异常处理精细化。
        问题：文件操作使用泛型 Exception。
        建议：捕获具体异常类型（如 FileNotFoundError），
```

评分项	得分	满分	评语
Student类设计	15	15	Student类设计完整，包含所有必需属性和方法，如_init_, add_score, get_total_score等
添加/删除学生	8	10	添加学生功能完善，但删除学生功能存在索引问题且缺乏年龄范围验证
成绩管理	15	15	成绩管理功能完整，包含添加、修改成绩和计算总分平均分，且有成绩范围验证
查看功能	10	10	查看功能实现良好，能显示所有学生信息和单个学生成绩
菜单界面	8	10	菜单界面清晰但缺少修改学生信息和修改成绩的选项，用户交互友好但可改进
统计功能	10	10	统计功能完善，包括成绩排名、各科平均分和及格人数统计
文件操作	8	10	文件操作功能实现但错误提示不够详细，缺乏必要字段验证
异常处理	4	5	有基本异常处理但不够全面，如主循环使用了裸异常捕获
代码规范	5	5	代码规范良好，命名规范，缩进统一，结构清晰
注释质量	4	5	注释质量不错但可增加模块级和类级的docstring
程序健壮性	5	5	程序整体健壮，对异常输入有基本处理

图 3 详细评分结果

Fig.3 Detailed scoring results

..... 下转第174页

要不断更新和完善。未来,应继续探索更加高效、准确的网络恶意入侵检测方法,为网络安全领域的发展贡献更多的力量。希望本文研究能够为相关领域的研究者提供一定的参考和启示,共同推动网络安全领域的进步和发展。

参考文献

- [1] 杨焯.基于改进BP神经网络的无线网络恶意入侵检测方法[J].电子元器件与信息技术,2023,7(11):75-78+82.
- [2] 王心怡,行鸿彦,侯天浩,等.基于演化博弈的无线传感器网络入侵检测研究[J].电子测量与仪器学报,2023,37(10):97-105.
- [3] 张明明,刘凯,李贤慧,等.基于广义神经网络的网络攻击检测与分类方法[J].信息安全研究,2023,9(6):593-601.
- [4] ZHENG R,ZHU J,ZHANG M,et al.An Anomaly Recognition and Autonomic Optimization Method to User's Sequence Behaviors for D2D Communications in MCC[J].IEEE Access,2018,6:63005-63020.

- [5] AGEEV S A,AGEEVA N S,KARETNIKOV V V,et al. Algorithm for Online Detection of Traffic Anomalies in High-Speed Enterprise Multiservice Communication Networks[J].Automatic Control and Computer Sciences, 2022,55(8):1068-1079.
- [6] 徐婷,郭春,申国伟,等.基于网络通信行为特征的间谍软件检测方法[J].计算机与数字工程,2022,50(10):2246-2251+2296.
- [7] 李红映,张天荣.移动无线传感网络通信异常行为识别方法研究[J].传感技术学报,2022,35(2):240-245.
- [8] 王生玉.基于多维相似度的网络传输通道恶意入侵检测方法[J].科技通报,2021,37(11):57-60.
- [9] 董峰,张秋霞.一种恶意节点攻击的无线传感器网络入侵检测方法[J].计算机技术与发展,2017,27(2):86-89.
- [10] 付吉菊.交互式网络恶意入侵跳频数据特征自动挖掘方法[J].宁夏师范学院学报,2022,43(7):72-79.
- [11] 马吉,杜永文,夏金棕.基于独立监督网络的选择性转发攻击检测[J].传感技术学报,2022,35(4):538-544.

..... 上接第47页

并记录错误日志。

(4) 类设计进阶。

问题: StudentManager 类职责较多。

建议: 考虑拆分为 FileHandler、UIManager 等独立类,提升代码灵活性。

(5) 排序效率优化。

建议: 使用 Python 内置排序方法提升效率,如下:
sorted_students = sorted(students, key=
lambda x: x.get_total_score(), reverse=True)

鼓励与展望:

你的表现令人印象深刻! 这个系统已具备生产环境应用的基础品质。后续可以考虑:

实现 CSV 导出等扩展功能,增加单元测试保证代码质量,学习设计模式优化架构。

继续保持这份对代码质量的追求,你一定会成长为出色的软件工程师! 如果有任何疑问,欢迎随时讨论。

5 结语

本文提出了一种基于大模型智能体的代码分析与评测系统研究与应用,通过多智能体协作机制和基于功能实现的评价体系,有效解决了高职编程教学中的关键问题。系统采用 Dify 平台构建,集成 DeepSeek V3 模型,实现了代码分析、错误诊断、功能验证等智能化功能。

系统的主要技术创新体现在四个方面: 基于 Dify 的多智能体协作架构显著降低了开发难度和维护成本;

职业教育导向的评价机制以功能实现为主导,符合职业教育“重实践、重应用”的培养目标; 细粒度功能分解将复杂的编程评价任务分解为可量化的功能点,提高了评价的客观性和一致性; 智能体角色专门化通过专门配置实现任务的精细化分工和专业化处理。

实验结果表明,系统在功能性能和用户体验方面均取得了显著成效,相比于传统 OJ 系统在教学辅助效果上有显著提升。系统在提升教学效率、评价公平性和学习体验等方面具有重要应用价值,为编程教学的智能化转型提供了重要的技术支撑和实践经验。虽然系统在计算资源需求、创新性评估和多语言支持等方面仍存在局限性,但其成功应用验证了大模型智能体在高职编程教育领域的巨大潜力,为智能化编程教学工具的发展奠定了基础。

参考文献

- [1] 李戈,彭鑫,王千祥,等.大模型:基于自然交互的人机协同软件开发与演化工具带来的挑战[J].软件学报,2023,34(10):4601-4606.
- [2] LANG G,TRIANTORO T,SHARP H J.Large Language Models as AI-Powered Educational Assistants: Comparing GPT-4 and Gemini for Writing Teaching Cases[J].Journal of Information Systems Education, 2024,35(3):390-407.