



计算机科学

Computer Science

ISSN 1002-137X, CN 50-1075/TP

《计算机科学》网络首发论文

题目：检索增强生成（RAG）综述：方法与应用
作者：王鑫林，李岩，马超凡，李硕
网络首发日期：2026-03-18
引用格式：王鑫林，李岩，马超凡，李硕. 检索增强生成（RAG）综述：方法与应用[J/OL]. 计算机科学. <https://link.cnki.net/urlid/50.1075.tp.20260317.1842.019>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

检索增强生成（RAG）综述：方法与应用

王鑫林^{1, 2} 李岩¹ 马超凡³ 李硕¹

1 中国科学院沈阳自动化研究所 辽宁 沈阳 110016

2 中国科学院大学 北京 100049

3 中原工学院 软件学院 河南 郑州 450007

(2020904030@chd.edu.cn)

摘要 大语言模型凭借着类似人类的文本生成和自然语言理解能力，正在深刻改变人工智能的发展格局。然而，由于其训练语料的封闭性与更新滞后，它们在面对动态更新的事实信息和专业领域的长尾知识等场景时，生成的回答往往会偏离事实。为此检索增强生成（RAG）通过集成外部知识库，扩展了大语言模型的知识范围，并辅助其生成更加准确和高质量的答案。区别于以往按流程环节划分的方式，该文创新性地以“解决核心挑战”为主线，将现有的 RAG 方法划分为分块优化、检索改进、上下文压缩和知识图谱融合四大类别，系统梳理了各类方法的代表性工作与技术机制。随后，本文总结了 RAG 在多个专业领域的典型应用，并在最后探讨了未来的研究方向，为研究人员提供了清晰的技术脉络和实用的方法选型参考。

关键词：大语言模型；检索增强生成；分块优化；检索改进；上下文压缩；知识图谱融合

中图分类号 TP391

Retrieval-Augmented Generation (RAG): A Survey of Methods and Applications

WANG Xinlin^{1,2}, LI Yan¹, MA Chaofan³ and LI Shuo¹

1 Shenyang Institute of Automation, Chinese Academy of Sciences, Shenyang, Liaoning, 110016, China;

2 University of Chinese Academy of Sciences, Beijing, 100049, China

3 School of Software, Zhongyuan University of Technology, Zhengzhou, Henan, 450007, China

Abstract Large language model (LLM), endowed with human-like capabilities in text generation and natural language understanding, are profoundly reshaping the landscape of artificial intelligence. However, due to the closed nature and lagged updates of their training corpora, LLM often generate responses that deviate from factual accuracy when confronted with dynamically updated information or long-tail knowledge in specialized domains. To address this limitation, Retrieval-Augmented Generation (RAG) extends the knowledge scope of LLM by integrating external knowledge bases, thereby assisting them in producing more accurate and higher-quality answers. Distinct from prior classifications based on processing stages, this paper innovatively categorizes existing RAG approaches around core challenges to be addressed, dividing them into four major categories: chunk optimization, retrieval enhancement, context compression, and knowledge graph integration. We systematically review representative works and technical mechanisms within each category. Subsequently, we summarize typical applications of RAG across various specialized domains, and finally discuss future research directions, providing researchers with a clear technical roadmap and practical guidance for method selection.

Keywords Large Language Model; Retrieval-Augmented Generation; Chunk Optimization; Retrieval Enhancement; Context Compression; Knowledge Graph Integration

1 引言

近年来，基于大规模语料库进行预训练的大型语言模型（Large Language Model, LLM，以下简称大语言模型），如 BERT、RoBERTa、Llama、Qwen 和 T5 等系列，凭借其强大的表征能力与泛化能力，在各类自然语言处理（Natural Language Processing, NLP）任务中均取得了卓越的性能表现。例如在机器翻译、文本生成以及

情感分析等任务中，这些 LLM 展现出了显著的优势。同时 LLM 规模的急剧增长进一步赋予了它们“涌现能力”，使其成为众多人工智能应用中的核心要素。例如 ChatGPT 和 PaLM 拥有数十亿参数，在教育、代码生成和推荐等复杂任务中展现出巨大潜力。

然而，LLM 对预训练静态数据的过度依赖也带来了严重的局限性。预训练数据存在固定不

基金项目：国家自然科学基金（No. 42206196、No. U23A20645）

National Natural Science Foundation of China. (No. 42206196, No. U23A20645)

通信作者：李硕（shuoli@sia.cn）

变、时效性差以及缺乏垂直领域知识等问题，导致这些模型常常生成看似连贯且可信，但实际上不正确的信息，这种现象通常被称为“幻觉”。该问题在需要准确、最新且与上下文紧密相关的响应的应用场景中尤为突出，例如医疗保健、法律系统以及实时客户支持等领域。已有研究表明，在医疗问诊场景中，LLM 可能生成不符合临床指南甚至具有潜在风险的诊疗建议，例如 Singhal 等人提出的 Med-PaLM^[1]模型在医生人工评估中仍有 10% 左右的回答被判定为包含潜在不安全或不准确的医学建议；在法律问答场景中，Lee^[2]等人指出 LLM 可能会捏造判例、错误引用法条或给出不准确的法律解释，严重影响其在真实法律场景中的可靠性。传统的解决方式是使用最新的相关知识对模型进行进一步预训练或监督微调^[3]。但是这种方法不仅成本高昂，还面临特定领域数据与预训练数据之间存在显著分布差异的问题，使得模型在整合新知识的同时容易损害已有的通用能力^[4]。此外还可能引发隐私泄露等安全隐患。Google Research 最近的一项研究进一步强调了使用监督微调来更新知识的潜在风险，尤其是在新知识与预训练知识冲突的情形下。研究发现通过监督微调获取新知识可能使模型形成新的幻觉，甚至会经历严重的“灾难性遗忘”，即模型丧失原有的知识和能力^[5]。

为有效解决上述问题，Lewis 等人于 2020 年提出的检索增强生成（Retrieval - Augmented Generation, RAG）^[6]技术成为一种极具潜力的解决方案。与需要修改模型架构或重新预训练的传统方法不同，RAG 则通过引入额外的检索模块，将外部知识融入大语言模型的生成过程，缓解因依赖静态数据而带来的挑战。这一机制使 LLM 不仅可以利用其在预训练阶段获得的通用知识，还可以借助实时检索获得最新的特定领域

信息来生成响应，从而生成更准确和可靠的答案。具体而言，RAG 系统主要包含三个关键步骤：索引、检索、生成。三者并非孤立执行，而是通过“知识表征-精准匹配-信息融合”形成紧密的协同闭环，同时各步骤衔接环节的合理性直接决定系统整体性能。各步骤核心流程及协同机制如下：在索引阶段，构建一个覆盖广泛主题和领域的外部知识库，并将其中内容划分为可管理的文本块，以支持高效的索引与检索操作。这一阶段为后续检索环节提供了“可精准匹配”的知识基础。在检索阶段，RAG 通过关键字匹配或语义向量相似度从知识库中检索与用户查询相关的文本块。该阶段输出的高质量文本为生成环节提供精准的知识补给。在生成阶段，RAG 将检索到的文本块和用户查询整合到一个预设的提示词模板中，LLM 根据此提示词生成所需要的输出。

由于 RAG 的三大关键步骤之间存在紧密的协同关系，所以各阶段之间的衔接质量将直接影响整体性能。例如，索引阶段的文本分块粒度会直接决定后续检索环节的效率与精度，分块过粗或过细会导致检索到的文本冗余或语义不完整；在检索与生成环节衔接中，检索环节得到的相关性文本会对生成结果的准确性造成直接影响，高相关的文本能够弥补 LLM 静态预训练知识的不足，提升生成内容的事实一致性。低相关的文本会增加 LLM 的信息融合难度，从而干扰 LLM 的生成逻辑导致生成结果偏离主题。总体而言，RAG 系统通过三大步骤协同配合，确保了生成的答案紧密锚定在检索到的信息（即“记忆”）中，使模型生成的答案能够与最新的世界知识保持一致。因此，RAG 技术能有效提升了 LLM 的性能，近年来吸引了越来越多的研究关注。

虽然 RAG 的出现为缓解 LLM 幻觉提供了一种可行方案, 但是 RAG 在实际应用中仍面临着几个影响其有效性的关键问题。这些问题可大致分为知识库质量参差不齐和结构缺失、内容分块策略设计、检索策略、上下文长度过长。其中, 知识库的质量与结构缺失是最基础性的问题, 它直接决定了分块、检索策略的优化空间与实施效果; 内容分块与检索策略是执行层主要面临的问题, 其合理性会共同影响上下文的组织与利用效率, 从而共同加剧或缓解上下文长度过长的问题; 上下文长度过长则主要影响终端 LLM 的生成效果。这四类问题相互作用, 共同制约 RAG 系统的整体性能和生成质量。具体分析如下:

1、知识库质量参差不齐和结构缺失。在实际应用中, 因为知识库往往涵盖教科书、科研论文、技术手册等多种形式, 所以不同机构、作者或系统在记录同一领域知识时, 往往采用了不同的表述方式和术语规范。例如, 同一概念在不同文档中可能会使用不同的名称或缩写, 甚至出现表述歧义。这种不统一的表达方式使得大量知识呈现出扁平化特征, 缺乏必要的交叉引用与层次化组织, 导致知识之间的内在逻辑关联无法有效显现。作为 RAG 外部知识的来源, 知识库是决定 RAG 性能上限的底层基础, 其质量和结构缺陷会直接放大后续分块与检索环节的优化难度。一方面会增加文本分块的设计难度, 另一方面, 语义模糊与逻辑缺失会导致检索模型难以精准捕捉核心知识。尽管 RAG 系统试图通过将知识库划分成更小的块来简化管理和提升索引效率, 但这种方法无意中丢失了重要的上下文信息, 不仅会影响检索准确性和对上下文的理解, 还会使得相关知识点之间的联系变得薄弱, 导致理解断裂, 降低了专业领域知识的有效利用率。

2、内容分块策略设计。虽然将知识库划分为可管理的文本块有助于构建高效索引并提升检索速度, 但不合理的分块方式可能导致上下文信息的丢失和语义割裂, 从而限制了检索质量。传统的几种分块方法各有局限: 固定长度分块按预设字数或 token 数切分文本, 虽然简单高效, 但通常在句子中间截断, 破坏文本的逻辑结构和语义完整性。基于句子的分块利用句子边界作为自然断点, 避免了语义碎片化, 但未考虑句子之间的上下文依赖与知识层级关系。基于段落的分块保持了原文段落结构, 但忽视了知识库中可能存在的布局信息 (如标题、列表、表格等), 限制了结构性知识的有效表达。因此传统分块策略虽具效率优势, 但难以兼顾语义完整性与结构感知, 这会让 RAG 系统在检索阶段难以捕捉完整的语义单元, 导致检索结果片面; 此外还会产生大量冗余和无效文本块, 增加了检索筛选难度, 并会使后续拼接的上下文包含过多无效信息, 导致生成质量下降。

3、检索策略。检索策略通常被归为两类: 稀疏检索 (Sparse Retrieval) 和稠密检索 (Dense Retrieval)。稀疏检索 (例如 BM25^[7]、TF-IDF^[8]) 通常依赖于关键词匹配的搜索制度, 这种方法的优势在于检索速度快, 但是它的无训练特性使其检索性能严重依赖于数据库和查询的质量。所以当查询较为复杂、语料库中含有大量的专业术语时, 检索结果的准确性会显著下降。相比之下, 稠密检索 (例如 DPR^[9]、Contriever^[10]) 将查询和知识库嵌入到具有一定标准的连续向量空间中, 用向量相似度来衡量语义相似性, 在检索准确率上通常优于稀疏检索。然而, 稠密检索在大规模语料环境下的检索速度较慢, 限制了其在实时场景中的应用。但在某些情况下无论使用何种检索策略, 都会受到检索结

果和下游任务之间不匹配的限制，即使检索到的内容与查询高度相关，但并没有对生成任务有实际帮助，甚至会让 LLM 生成不相关的答案。检索策略不仅会影响生成阶段的上下文的组织效果，还会与分块策略产生交互效应，即分块不合理会进一步降低检索效果。

4、上下文长度过长。在 RAG 框架中，检索阶段可能返回包含大量信息的支持文档，这些文档在生成阶段被拼接为提示输入到 LLM 中。当上下文长度超过 LLM 的固定上下文窗口（通常为 2k - 32k tokens）时，超出部分将被截断或经过压缩总结处理，这不仅存在信息缺失问题，还破坏了自然语义单元和逻辑性。此外，长上下文通常由多条提供重要知识的证据与大量无关噪声共同构成。过量且分散的信息会削弱 LLM 在关键信息上的注意力，增加信息处理的复杂性，对 LLM 的生成质量产生不利影响。因此当 RAG 系统处理的上下文过长且未经过有效处理时，冗余与噪声信息将直接影响生成阶段的整体质量与准确性。

为了解决这些缺陷，新的技术在传统 RAG 的框架基础上添加了额外功能模块，演变成多种 RAG 范式。当前已有综述从不同角度对这些方法进行了归纳。例如，Gao^[11]等人主要聚焦于 RAG 的基础架构的演变历程，将 RAG 划分为 Naive RAG、Advanced RAG、Modular RAG 三大类，强调系统模块化程度与功能的逐步提升；Fan^[12]等人依据 RAG 的三大关键流程、培训策

略，对 RAG 方法进行了分类与比较；Zhao^[13]等人从用户查询对外部数据依赖的本质差异出发，强调根据问题的认知层次与知识需求进行 RAG 分类。此外，还有部分研究聚焦于特定技术融合方向的发展脉络，例如 Zhang^[14]等人的专门探讨了 RAG 与知识图谱结合，重点分析如何利用结构化语义关系增强检索精度与推理能力；而 Singh^[15]等人则系统分析了 RAG 与 Agent 的协同机制，强调其在多轮交互、工具调用与任务规划中的应用潜力。

本综述旨在对 RAG 进行全面分析，详细介绍了其分类、机制、应用和未来的研究方向。具体而言，在第二章我们从解决核心挑战的角度出发，将现有的 RAG 方法系统性地归纳为四大类别，覆盖了 RAG 流程的各个环节，为分析和比较不同技术提供了清晰的结构；在第三章系统介绍了常用的基准和数据集、评价指标、以及具有代表性的开源项目；在第四章我们介绍了 RAG 的一些代表性应用；最后在第五章我们探讨了 RAG 的未来研究方向。整体而言，本综述不仅在理论层面构建了系统化的分类方法，也在实践层面为 RAG 的应用落地提供了创新性思路，为相关研究人员提供更清晰的技术脉络，使其能够更有效地根据不同应用场景选择合适的方案。对推动 RAG 在智能对话、推荐系统和自动化推理等领域的发展具有积极意义。文章的结构详见图 1。




图 1 文章结构图

Fig1. Article structure diagram

2 RAG 方法概述

初级 RAG 框架只有索引、检索、生成三个步骤。为了提升检索质量,高级 RAG 会在检索前或检索后增加一些操作,甚至有的研究人员为了适配特定任务,会对编码模型进行微调。随着 RAG 技术的进一步发展和演变,新的技术突破了传统的初级 RAG 检索、生成框架,演变成模块化 RAG 框架。在结构上它更加自由的和灵活,引入了更多的具体功能模块,例如查询搜索引擎、融合多个回答。技术上将检索与微调、强化学习等技术融合。流程上也对 RAG 模块之间进行设计和编排,出现了多种的 RAG 模式。

我们将模块化 RAG 框架分为四种不同的类别,分别是分块优化的 RAG 方法、检索端改进 RAG 方法、减少上下文输入的 RAG 方法以及知识与知识图谱结合的 RAG 方法。其中,关于分块优化的 RAG 方法的核心在于对“分块”本身的再定义与再设计,它不再将分块视为简单的预处理步骤,而是引入语义或视觉等智能、自适应的分块逻辑,使其成为动态的、可学习的、与模型深度结合的智能过程,实现检索精度与上下文连贯的最佳平衡。关于检索端优化的 RAG 方法则致

力于将传统“固定化”的检索模式转变为“主动化”与“适配化”的过程,这类方法都是围绕检索时机、检索方式、检索算法与检索内容来优化 RAG,实现检索与生成的深度协同,从而提升系统整体准确性。关于减少上下文输入的 RAG 方法,其核心思路是在生成阶段对检索到的文档进行高效压缩与精炼。这类方法通过提取关键信息、构建语义摘要、过滤无关噪声等手段,将长文档转化为简洁而富含知识的表示,使 LLM 能够更聚焦、更高效地利用外部知识,从而在降低计算负担和推理延时的同时提升生成质量。与知识图谱结合的 RAG 方法则以结构化知识图谱替代非结构化文本作为检索对象。这类方法研究主要侧重于提升知识图谱的构建质量、设计高效的图检索与推理策略、优化图谱与 LLM 之间的信息对齐机制,从而在复杂推理任务中实现更精准、更可靠的知识增强生成。每类方法的研究都有很多优秀的成果。下文将逐一详细介绍这些方法的具体实现和技术特点。

2.1 分块优化的 RAG 方法

在经典 RAG 架构中,知识库预处理阶段的内容分块策略会直接影响检索效率与精度。传统

的内容分块方法通常采用固定长度分块、句子分块、段落分块等方式，这些策略虽然能加快检索速度，但也存在明显缺陷：例如语意连贯性被打断、分块不精确等问题。为了平衡语义独立性和上下文连贯性，许多 RAG 框架从优化分块这一

角度出发，诸如 CFIC^[16]，LE^[17]，MOG^[18]，LumberChunker^[19]，VGC^[20]，DCS^[21]，Late Chunking^[22]等框架。下图为分块优化 RAG 方法流程。




图 2 分块优化 RAG 方法流程

Fig2. Workflow of chunking-optimized RAG methods

CFIC 是一种跳过分块的上下文检索方法，它将整体内容和用户查询送入 LLM，用编码后得到隐藏状态进行内容检索。CFIC 进一步通过即受限句首解码和跳跃解码两种策略识别并跳过无关内容，精准定位所需要的内容来增强其性能。该框架在公开问答数据集的表现优于传统分块加排序方法，避免了分块导致的语义丢失问题，为分块优化提供了新见解。LE 框架与 CFIC 方法类似，也是一种无需分块的架构。它为了保证全部内容得到输入，联合滑动窗口机制和 LLM 得到每个句子的语义表征。该框架进一步通过位置目标感知函数，对每个语句的位置进行建模，越靠近用户查询的语句，被认为相关性越高，在感知函数中越容易受到关注。最后经过多阶段学习(远程监督、弱监督、微调)，在每阶段相应数据集训练下，该框架拥有了上下文的表示能力和语义区分能力。该框架不仅在各种基线任务上表现优异，同时在运行效率上具有显著优势，能在较低的计算成本下达到优异的性能。

MOG 框架受混合专家的启发，引入了混合粒度，可以动态地根据不同知识库采用不同的切

块方法。MoG 通过引入一个路由器模块，该模块采用软标签的损失函数进行训练，能根据用户查询动态选择最优的分块粒度，从而平衡检索的精确度和召回率。此外，作者还将 MoG 进一步扩展为 MoG-Graph (MoGG)，将参考内容文档预处理为图结构，以检索分散在不同位置的有效文本片段，进一步提升了跨文档检索的能力。实验表明，MoG 和 MoGG 都能有效预测最佳的分块方法，并在许多下游任务中表现优异。

LumberChunker 是一种基于 LLM 的动态文本分块方法。它首先将目标文档按照段落切分，并为每个段落赋予一个唯一的递增 ID，并将它们依次拼接形成一组段落序列；然后将该组段落输入 LLM，通过提示词引导 LLM 动态识别内容显著变化的分界点，并以此作为分块的分割点。重复迭代该过程，从上一次分块的分割点重新构建段落序列。LumberChunker 方法确保了每个分块内部的语义连贯性，又能让每个分块与相邻分块有所区别。它有效地提升了检索效率，解决了传统分块方法在复杂叙事文本中信息割裂或冗余的问题。

VGC 与现有的启发式规则分块方法不同, 它创新性的利用文档中的视觉特征 (如图表、标题层级) 来指导文本切块。该方法通过使用大型多模态模型 (如 Gemini-2.5-Pro) 对 PDF 文档进行批量处理 (每批 4 页), 结合跨批次上下文保留机制, 强制生成具有三层次标题结构 (文档标题 > 章节标题 > 子标题) 的上下文感知 chunk, 并通过智能内容保留规则 (如步骤完整性、表格行独立分块) 和连续性标记系统 (CONTINUES 标志), 精准提取视觉元素描述从而确保文档结构和语义关系的完整性。该方法利用视觉引导切分文本, 解决了 LLM 在处理超长文档阅读理解任务中面临的上下文截断与信息丢失问题。DCS 是一种动态切分与选择方法, DCS 首先基于标点将长文本分解为句子序列, 然后经邻域合并策略扩展单句上下文。它利用 BERT 模型句级编码上下文并计算相邻句子间的语义相似度, 结合预设阈值筛选最大语义不相似度位置作为初始分块边界, 迭代优化确保块长符合预设约束; 随后构建问题感知分类器, 通过提取上下文 - 问题对的边界 token 特征与注意力池化特征构建输入, 以二元交叉熵损失训练实现 chunk 相关性判断, 最终结合 LLM 上下文窗口限制动态确定压缩比, 筛选出高相关 chunk 并按原序拼接后输入 LLM 完成推理。这个过程允许 LLM 在遵守长度限制的同时最大程度地保留了的相关内容。

传统的分块方法通常将文本划分为可管理的块, 然后对每个块分别应用嵌入模型, 生成对应的向量表示, 并通过计算用户查询向量与文本块向量之间的余弦距离来衡量相关性。而 Late Chunking 则采用相反的处理顺序: 它首先对整个上下文进行整体编码, 生成全局向量表示, 然后依据预设的分块边界提示, 在嵌入空间中对对应位置进行均值池化, 以获得每个分块的向量表

示。由于分块发生在嵌入之后, 所以 Late Chunking 能够捕捉完整上下文信息。针对嵌入模型无法一次性处理超长文档的问题, 作者进一步提出了 Long Late Chunking 方法, 并引入了一种跨度池化的训练方法以进一步提高性能。

总的来说, 关于分块优化的 RAG 方法可大致分为“无需分块”和“动态分块”两类, 无需分块方法包括 CFIC 和 LE 框架, 动态分块方法包括 MoG/MoGG、LumberChunker、VGC 和 DCS 等代表性工作。“无需分块”方法通过直接对整体上下文建模, 避免了预处理分块与多粒度检索带来的额外开销, 所以在计算效率上具有更高的优势。但受限于 LLM 上下文窗口大小, 这类方法在处理长文本或复杂文档时, 可能存在关键信息覆盖不足的问题。动态分块方法通过依据语义变化、文档结构、视觉特征自适应调整分块粒度, 能够更好地保持语义完整性和上下文连贯性, 但通常需要引入额外的模块或处理流程, 计算成本和系统复杂度相对较高。

2.2 检索端改进的 RAG 方法

在 RAG 系统检索阶段, 传统检索方法是利用稀疏检索或稠密检索, 或者将二者结合, 检索与查询有关的内容文档。传统检索程序虽然固定简单, 检索效率高, 但是检索到的内容很容易出现偏差, 这种问题在遇到复杂查询时尤为明显。因此有许多研究者从检索端角度优化 RAG 框架, 使检索到的内容更加准确, 从而让大模型能根据更准确的外部知识, 增加生成质量。例如, InteR^[23] DAPR^[24], FLARE^[25], Adaptive-RAG^[26], Self-RAG^[27], SIMLM^[28], ARL2^[29], BGM^[30], Selfmem^[31], Realm^[32]等框架从检索时机、如何检索、检索什么内容或者其他方面进行优化, 解决了 RAG 框架在检索这一步骤的缺陷。下图为检索端改进 RAG 方法流程。




图3 检索端改进 RAG 方法流程

Fig 3. Workflow of retrieval-side enhanced RAG methods

InteR 是一种新型信息检索框架，它将检索模型与 LLM 协同作用，利用二者优势解决传统信息检索的局限性。InteR 框架中的检索模型利用 LLM 生成的回答扩查询，LLM 则根据检索模型检索到的内容文档生成更准确的回答。并且让这一过程重复迭代，让检索模型检索到的知识和 LLM 生成的答案互相补充，直至生成最准确的答案。实验表明，该方法在零样本设置下能显著提升检索性能，甚至能超越现有一些依赖相关性标注监督的检索模型。DAPR 框架从传统检索模型容易忽略文档结构信息（如标题、章节、跨段落关联）角度出发，提出两种增强方法，一种是将稀疏检索与稠密检索结合，一种是在参考文档中注入标题、关键词等信息。此外该作者还构建了基准数据集，为长文档细粒度检索研究提供了标准化评估平台。FLARE 是一种主动多次检索增强生成框架，除了刚开始它会根据用户查询检索相关内容文档，它后续还会根据 LLM 生成的答案进行检索。具体来说，在生成每个句子时，该框架会预测生成的句子是否包含低置信度的词元，如果包含，则将该句作为查询检索相关内容文档，重新生成更准确的句子。FLARE 采用边生成边检索的机制，在多项长文本任务中表现优异，它作为即插即用、无需额外训练的 RAG 框架，适用于各种 LLM，为动态知识整合提供通用解决方案。

Adaptive-RAG 框架会根据查询的复杂度，将其分为三类：无需检索、单步检索、多步检索，并为每类复杂度选择最合适的策略生成答案。该方法通过自动标注训练数据（利用模型预测结果和数据集固有偏差）实现了无需人工标注的高效分类。实验表明，Adaptive-RAG 在多个开放域问答数据集上显著优于现有方法，平衡了性能与资源消耗。传统 RAG 框架在检索时并不会考虑大模型内部知识是否拥有答案，以及检索到的内容文档是否与查询相关，这可能导致增加额外计算开销或生成内容质量下降。Self-RAG 框架从该角度出发，引入自我反思机制，用离线插入反思标记（检索标记、批评标记）的数据集训练出反思模型，该模型能够生成反思标记来指导检索和生成过程。实验表明，Self-RAG 在多项任务（如开放域问答、推理和长文本生成）中显著优于传统 RAG 方法。SIMLM 则聚焦于检索算法的改进，它是一种专门的密集段落检索方法，采用表示瓶颈架构，通过自监督预训练学习将文本信息映射到向量空间中，然后通过向量点积或余弦相似度来衡量相关性。SIMLM 由一个深层编码器和浅层解码器组成，中间通过表示瓶颈连接。该方法采用替换语言建模目标，先生成一个随机掩码的文本段，编码器生成表示瓶颈，解码器利用该瓶颈重构原始文本段，这种设计迫使编码器必须将关键语义信息压缩到瓶颈向量

中, 有助于学习更鲁棒的段落表示, 从而提升其在稠密检索任务中的表现。

ARL2 方法旨在提升 LLM 和检索器的协同效果, 该方法将 LLM 作为评估器, 通过自适应的相关性标注和自训练策略来训练检索器。它首先利用 LLM 对相关证据进行标注和评分, 构造多样化和高质量的训练集, 并结合对比学习和成对排序损失优化检索器。此外还采用聚类策略生成多样化训练数据, 并通过自训练策略动态减少标注成本。在推理阶段, 将训练好的检索器与 LLM 结合, 将检索到的文档重新排序和集成预测, 然后生成答案。实验表明, 该方法拥有强大的零样本泛化能力, 为 RAG 提供了高效且低成本的解决方案。BGM 与 ARL2 目标类似, 它则是建立起 LLM 和检索器的桥梁, 旨在解决传统检索器与大型语言模型之间的偏好差异问题。但该方法固定检索器和 LLM, 重新训练一个轻量级的序列到序列的桥梁模型架构, 能够动态选择、重新排序或者重复检索到的相关文档, 可以让上下文更符合 LLM 的偏好。该方法首先通过贪心搜索算法合成适用于监督学习的银质段落序列, 然后利用银质段落序列对桥梁模型进行监督学习训练, 将监督学习训练后的桥梁模型作为策略模型, 最终利用下游任务性能作为奖励进行强化学习训练。

Selfmem 框架通过引入自记忆和迭代生成机制来解决传统 RAG 框架中固定语料库对生成质量的限制。它由检索增强生成器和记忆选择器两个关键组件组成, 检索增强生成器在初始阶段基于输入和外部检索的记忆生成多个候选输出, 形成一个无限的内存池, 并使用记忆选择器来选择最优输出作为后续生成轮的记忆输入。这一过程迭代进行, 使得模型能利用自身的高质量输出作为动态记忆, 突破传统 RAG 框架依赖固定检索

语料的限制, 从而同时优化“更好的记忆提升生成”和“更好的生成反哺记忆”的双重目标。

Realm 旨在用更模块化和可解释的方式捕获知识, 预训练出一个带有潜在知识检索器的语言模型, 显示地将外部知识库 (如维基百科) 整合到语言模型预训练中, 来增强知识的获取与表示。它首先以无监督的方式并来利用掩码语言模型作为学习信号, 同时反向传播更新检索器参数来训练出潜在知识检索器。知识增强编码器则基于检索到的文档和输入生成预测答案, 通过跨注意力机制实现丰富的信息交互。该模型采用端到端的模式优化检索与生成, 不仅可以高效处理百万级文档检索, 还容易在多应用场景中部署。

上述方法虽然均从检索端改进, 但由于不同策略设计所以在适用场景边界上存在明显差异。稀疏和稠密检索融合方法 (如 DAPR、SIMLM) 在一次性检索中兼顾文档结构信息与语义表示, 实现较高的精度检索, 适用于知识库结构清晰、内容相对稳定且对检索效率要求较高的场景。然而, 该类方法通常依赖一次性检索结果, 其性能在面对复杂推理需求或信息分散的长文本场景时存在一定局限。迭代或自适应检索方法 (如 FLARE、Adaptive-RAG、Self-RAG) 通过边生成边检索、查询复杂度分类或自我反思机制动态优化检索内容, 更适合开放域问答、长文本推理或知识分布分散的应用场景, 但相应地引入了更高的计算成本和系统复杂度。

2.3 减少上下文输入的 RAG 方法

在 RAG 系统的生成阶段, 查询会与检索到的完整文档一起拼接作为大模型的提示输入, 由此来生成答案, 会很容易出现上下文过长、无关信息冗余、噪声干扰等问题, 从而增加了计算成本与推理效率。为提升模型效率与生成质量, 有些研究者从压缩和过滤文本角度减少上下文输入, 提出优化方案, 诸如 xRAG^[33], MAIN-

RAG^[34] , IB-RAG^[35], LLMingua^[36] , LLMingua-2^[37] , FILCO^[38] , RECOMP^[39] , AMR-RAG^[40], FAVICOMP^[41], COCOM^[42]这些方法在减少上下文输入同时,会保留关键信息和

去除无关噪声。这些工作为降低 LLM 推理成本提供了实用解决方案,提升了 LLM 的高效性和可扩展性。下图为减少上下文输入的 RAG 方法流程。




图 4 减少上下文输入的 RAG 方法流程

Fig4. Workflow of RAG methods for reducing contextual input

xRAG 采用模态融合技术,将文档密集嵌入向量投影至语言模型表示空间,以单标记替代全文,实现 178 倍压缩。其仅需训练轻量级模态桥接投影器(参数占比<0.1%),检索器与语言模型参数冻结支持离线嵌入复用。实验表明,xRAG 在知识密集型任务上性能提升超 10%,接近未压缩模型,计算量降至 1/3.53,为高效检索增强系统提供新思路。MAIN-RAG 框架引入多智能体协作过滤与评分检索文档,动态调整相关性阈值,在保持高召回率的同时减少噪声。该免训练方法通过自适应机制和智能体共识提升答案准确性与系统可靠性,在问答基准测试中准确率提升 2-11%,减少无关文档干扰,提供高效可扩展的 RAG 解决方案。IB-RAG 提出基于信息瓶颈理论的噪声过滤方法,解决传统目标优化无法精确区分有用信息与噪声的问题。该方法通过最大化压缩内容与真实输出的互信息(保留有用信息)、最小化与检索段落的互信息(去除噪声),实现精准过滤。此外,信息瓶颈理论被应用于评估指标设计、监督微调数据选择和强化学习奖励构建,显著提升答案正确性与简洁性(压缩率 2.5%)。

LLMingua 是一种的粗到细的提示压缩方法,它通过三个核心模块实现高效压缩:1)预

算控制器:动态分配查询、提示、相关信息的不同压缩比例以保持语义完整性;2)迭代式词级压缩算法,通过考虑词间依赖关系保留关键信息;3)基于指令微调的分布对齐方法,缩小小语言模型与目标 LLM 之间的分布差异。实验表明,该方法在数学推理、复杂推理、对话和摘要四个任务中实现了最高 20 倍的压缩率,且性能损失极小。此后他们团队继续提出 LLMingua-2,该方法通过数据蒸馏技术从原始提示中提取关键信息,生成紧凑且语义保持的短提示,从而减少计算开销,同时保持任务性能。其核心创新在于提出任务无关的压缩策略,适用于多种下游任务(如问答、摘要等),无需针对特定任务微调。实验表明,LLMingua-2 在保持高准确率的同时,显著降低了提示长度和推理延迟,在各种场景中表现优异。

FILCO 方法区别于以往粗粒度的文章级过滤策略,采用细粒度的句子级上下文过滤机制。FILCO 基于词汇和信息论方法从三个维度筛选训练数据,分别是上下文是否包含输出、上下文与输出的 unigram 重叠程度、上下文对生成输出概率的提升程度。通过这些策略筛选的训练样本训练出的上下文过滤器,能够自动识别并保留最具支持性的文本内容,实现高效、精准的上下文过

滤。该方法在六个不同类型的知识密集任务中不仅提升了生成质量, 同时将输入长度减少了 44%-64%, 展示了其在实际部署中的实用性和通用性。并为提高 RAG 系统的可靠性提供了重要方向。RECOMP 是一种结合提取式与抽象式压缩的检索增强生成方法, 用于高效压缩输入上下文。提取式压缩器别编码输入查询和检索到的文档中的句子, 通过计算它们的相似度来选择最相关的句子。抽象式压缩器通过知识蒸馏从大规模的语言模型 (如 GPT-3) 中学习独立生成摘要的能力, 它将提取式压缩器筛选出相关句子综合生成高质量摘要。方法可以有效地将检索到的大规模文档压缩为简洁的摘要, 同时支持选择性增强 (在检测到检索到的文档与查询无关时返回空摘要), 并在保持端任务高性能的同时减少了计算成本。

AMR-RAG 实质是一种概念蒸馏技术的 RAG 框架, 它受基本概念在个体阅读理解中的支持作用的启发提出概念提取算法 (AMR)。该算法能将检索到与查询相关的支持文档转换成语义图结构, 并通过深度优先搜索 (DFS) 遍历图中的关键节点, 提取核心概念 (如命名实体、时间等), 同时过滤冗余信息。因此蒸馏后的概念比原始支持文档更加以知识为中心, 同时这些概念能明确限制 LLM 在推理过程中只关注重要信息。结果表明, 基于概念的 RAG 框架在长上下文场景下优于传统关键词提取、摘要生成等基线方法, 特别是随着支持文档数量的增加, 同时还表现出跨各种主干 LLM 的稳健性。FAVICOMP 是一种无需重新训练 LLM 的压缩上下文的方法。它的核心在于相关文本的熟悉度感知机制。首先 FAVICOMP 的压缩模型根据检索到的相关文档生成一个能够精确反映输入查询意图的简洁摘要, 目标模型则基于内部知识生成关

于查询的可能上下文。其次在解码阶段, 它结合并比较了二者生成的 token 概率, 选择概率更高的 token 进行最终相关文本生成。这种考虑到大语言内部知识的感知机制不仅有效帮助模型减少上下文信息的困惑度, 同时还能显著减少上下文长度。COCOM 的核心在于其自适应压缩机制。该方法依赖于压缩器模型与生成器模型的联合学习, 即用同一个模型进行压缩和生成任务, 并允许通过调整压缩率来权衡速度和生成质量。该方法在压缩上下文时会每个检索到的上下文段落独立压缩成上下文嵌入, 然后通过添加分隔符 (如[SEP]) 将它们组合起来, 作为 LLM 的输入。这种方法允许并行处理多个上下文, 显著提高了处理效率, 特别是在需要推理多个文档的复杂问答任务中。

2.4 与知识图谱结合的 RAG 方法

在传统的 RAG 系统中, 预先构建的知识库通常来源广泛, 如教科书、研究论文、行业报告和技术手册等。这些内容存在撰写规范不一、质量参差不齐、概念分散冗杂、缺乏统一的组织结构等问题, 导致知识呈现出扁平化、碎片化和多层次交织的特点, 从源头上降低了检索结果的准确性和相关性。为解决这一问题, 一种新兴范式——图检索增强生成 (GraphRAG) [43] 应运而生。GraphRAG 是 RAG 框架的一种结构化扩展形式。与传统 RAG 使用非结构化的纯文本知识库不同, GraphRAG 将知识库转化为结构化的知识图谱, 利用图结构作为知识的载体或索引机制。图中的节点表示知识实体或片段, 边则建模它们之间的语义依赖关系。GraphRAG 通过图结构的组织方式能够有效发现围绕某一主题或锚实体的知识片段, 此外还能利用图中的连接关系沿相关路径导航并同时在检索时动态修剪无关节点, 从而实现更全面、更高效、更精准的信息组织与检索。

GraphRAG 的工作流程与传统 RAG 一样，也可以分为三个关键步骤：索引、检索、生成。在索引阶段，GraphRAG 提取外部知识库的实体与语义关系，形成图结构以对外部知识进行建模，知识图谱既可以作为显式的知识表示形式（图即知识），也可作为高效的索引机制（图作为知识检索路径的结构索引）。在检索阶段，GraphRAG 基于图的规划器检索与用户查询相关的信息，该规划器可以是可学习的神经规划模块，也可以是传统的图算法（如最短路径、子图匹配等）。在生成阶段，GraphRAG 与传统 RAG 一致，都是将用户查询与检索到的知识整合到预定义的提示模板中，再将提示词作为 LLM 的输入，生成最终响应。借助知识图谱在概念关系建模和结构清晰性方面的优势，GraphRAG 在需要复杂推理、实体消歧或多跳问

答等任务中展现出卓越的能力，已成为 RAG 研究的重要方向之一。

GraphRAG 这种可行方案虽然能显著增强回答的准确性，但是当 LLM 从知识图谱寻找关键参考信息时，可能会出现知识图谱的质量比较低和规模比较大的情况，此时 GraphRAG 回答的准确性容易降低。所以现有一些研究从如何高效构建质量好的知识图谱、如何从知识图谱快速寻找所需要的参考信息等角度优化 GraphRAG 框架。诸如 KAG^[44]、KGR^[45]、iText2KG^[46]、GraphInsight^[47]、SKETCH^[48]、SGP^[49]、AMAR^[50]、GraphReader^[51]、Spider^[52]、KELP^[53] 等方法。它们从不同角度切入，对知识图谱构建与检索策略进行了系统改进，为 GraphRAG 在实际应用中的可用性与稳定性提供了保障。下图为与知识图谱结合的 RAG 方法流程。




图 5 与知识图谱结合的 RAG 方法流程

Fig 5. Workflow of RAG methods integrated with knowledge graphs

KAG 框架的核心特征在于它通过将 RAG 和知识图谱的双向增强，提升专业领域问答的准确性和逻辑性。首先该方法提出了一种对 LLM 友好知识表示框架，能够同时兼容同一知识类型（如实体、事件）上的无模式信息提取和有模式约束的专家知识构建，并支持图结构和原始文本块之间的双向索引表示，从而实现逻辑形式的统一表示、推理和检索。在检索阶段引入逻辑形式引导机制，将自然语言问题转化为语言和符号相结合的问题求解过程。在推理阶段对离线知识图

谱和在线检索阶段均进行语义推理，使得自动化产生的碎片化知识能够通过领域知识进行对齐和连接，增强检索的语义关联性。KGR 是一种在知识图谱基础上的修正框架，希望通过储存在知识图谱中的事实性知识来减轻 LLM 在推理过程中的事实幻觉。它首先从 LLM 生成的初始答案中提取所需要验证的原子事实声明，然后识别其关键实体并从知识图谱中检索相关子图三元组，筛选出最终的核心三元组。根据从知识图谱检索的事实声明来迭代修订将 LLM 生成的答

案, 直至生成的响应与知识图谱对齐。该框架无需人工干预, 全程依赖 LLM 自主执行, 在复杂推理任务 (如多跳问答) 中能显著提升事实准确性。

iText2KG 通过 LLM 的零样本能力优化知识图谱构建的方法, 使其具有无需后处理、主题无关的特性。该方法首先根据原始文档的预定义模式提取结构化信息, 使用 LLM 将原始文档重写为语义块; 然后迭代地从语义块中提取全局文档实体, 并用余弦相似度匹配新旧实体, 确保每个实体在语义上只有唯一的概念, 解决实体命名重复问题; 再根据全局或局部实体上下文检测已解析的实体语义上唯一的关系, 避免冗余和无关关系; 最后使用 Neo4j 图数据库表示实体和关系, 提供直观的图谱可视化。该方法具有高度的灵活性和普适性, 极大地提高了知识图谱构建的效率。GraphInsight 从 LLM 的固有的“位置偏差”出发, 旨在增强 LLM 理解图结构的能力。该方法主要由两种核心策略组成, 分别对应知识图谱的宏观层面和微观层面。一种是重新组织图描述序列, 将最关键的子图描述放置在 LLMs 的强记忆区域 (序列的开头和结尾), 以增强宏观整体记忆和理解能力。一种是针对 LLM 对图描述序列比较弱的记忆区域, 提取子图并构建轻量级外部知识库, 通过实时检索其邻居信息来增强 LLM 的微观理解能力。该方法通过智能体流程整合两种策略, 有效提高了 LLM 在各种图规模下的理解能力。

SKETCH 是一种基于大型语言模型的图卷积框架, 专为文本属性图 (TAG) 任务设计。该框架包括语义检索模块和结构检索模块, 语义检索模块利用全局嵌入相似性技术和 FAISS 引擎快速检索与目标节点语义相似的节点文本; 结构检索模块则通过 Jaccard 相似性和高效的 MinHash

算法, 识别具有共同邻居的节点以捕捉图结构信息。最后再将语义检索和结构检索模块获取的信息进行融合, 通过加权排名聚合机制生成统一的评分系统, 筛选出最相关的文本内容, 输入长上下文 LLM 进行训练和预测, 提高模型对文本和图结构的综合理解能力。SGP 框架旨在探索文本的图结构来指导 LLM 进行多步推理, 提升其在复杂自然语言场景下的推理能力。首先将无结构的段落转换为结构化的图, 然后根据不同的推理任务设计相应的图表示方法和规划策略, 最后指导 LLM 按策略遍历图并逐步推理答案。该框架通过结构化表示解决自然语言的模糊性, 在零样本设置下显著提升复杂推理任务的准确性。

AMAR 框架旨在通过知识图谱的多方面检索增强 LLM 再复杂知识推理中的表现。该方法首先从知识图谱检索实体、关系和子图三类知识, 并针对不同类型采用相应的检索策略, 随后将检索到的知识化为文本嵌入, 再通过交叉注意力和自注意力机制对齐不同方面知识的一致性, 减少噪声干扰; 然后通过相关性门控模块学习查询与检索知识之间的相关性, 自适应地决定哪些信息应被用于增强 LLM 的输出; 然后将筛选后的嵌入与查询结合输入 LLM 生成逻辑形式, 进一步优化后获得答案。GraphReader 是一种基于图的代理系统, 旨在通过将长文本组织成图结构, 并利用智能体自主探索图来增强 LLM 的长文本处理能力。该方法首先将长文本分割成离散的块, 提取关键信息和原子事实以构建出能够有效捕捉长文本中的依赖和多跳关系的知识图谱, 智能体再根据查询制定合理的规划, 接着利用预定义函数 (如读取块、探索邻居节点等) 探索图, 在此过程中不断记录相关信息, 最后将所有信息整合输送给 LLM, 利用链式思维生成答案。

Spider 框架旨在通过强化学习为 LLM 提供决定性的子图信息，从而增强 LLM 在图学习任务中的推理能力。Spider 框架由关键子图检测模块和决定性节点引导网络组成，前者利用深度和宽度代理自适应搜索目标节点的邻域，筛选出对 LLM 推理至关重要的子图；后者则通过梯度分析识别子图中对预测影响最大的节点，并以文本形式将这些节点信息提供给 LLM。KELP 框架旨在通过灵活的知识提取和路径选择机制增强大型语言模型的事实准确性。其技术路线分为三个阶段：知识路径提取即从知识图谱提取与输入问题相关的 1-hop 和 2-hop 路径作为候选知识路径；样本编码即使用经过微调的句子编码器在潜在语义空间中对输入查询和候选知识路径进行编码，以量化路径对问题答案的潜在影响，捕捉与查询直接和间接相关的关键知识；细粒度路径选择即基于两个覆盖规则（基于路径相似度得分的阈值和多样性控制参数）动态筛选最优路径作为上下文输入 LLM。

2.5 四类方法对比分析

总的来说，本文将现有的 RAG 方法划分为四大类别，每一类的适用场景和性能表现存在明显不同。对比结果如表 1 所示。

对于分块优化的 RAG 方法，它的核心思想是通过改进分块策略以更好地保持语义完整性，所以在长文档理解和信息定位任务中准确性提升比较高。这类方法通常引入了额外的预处理步骤

或模块，导致整体计算成本和推理延迟略高于基础 RAG，但由于该类方法通常只在检索前或编码阶段改动架构，因此部署复杂度处于中等水平。

对于检索端改进的 RAG 方法，其准确性提升主要来源于对检索过程的主动调控，这类方法能够动态识别信息缺口并补充关键证据，然而，检索过程的复杂化会带来较高的计算成本和推理延迟。同时，该类方法通常需要对检索器、生成模型协同设计，提高了系统部署和维护难度。

对于减少上下文输入的 RAG 方法，其设计目标是通过上下文压缩、证据筛选等手段，保留对生成结果最关键的信息。这类方法在保证生成质量的同时显著减少了 token 数和模型计算量，因此在计算成本和推理延迟方面具有明显优势。但由于信息被压缩或过滤，模型难以细粒度覆盖全部信息，使得准确性提升相对有限。这类方法通常以轻量级模块形式集成，部署复杂度较低。

对于与知识图谱结合的 RAG 方法，其准确性提升主要得益于结构化知识的引入，使模型能够显式利用实体和关系进行逻辑推理。但知识图谱的构建、图检索与推理过程本身具有较高的计算开销，导致整体计算成本和推理延迟相对较高。此外，该类方法需要依赖高质量知识图谱及专用的推理组件，使得部署复杂度较高。

表 1 RAG 方法对比分析

Table 1 Comparative Analysis of RAG Methods				
维度	分块优化的 RAG 方法	检索端改进的 RAG 方法	减少上下文输入的 RAG 方法	与知识图谱结合的 RAG 方法
准确性提升	较高	高	较高	高
计算成本	中等	较高	较低	较高
推理延迟	中等	较高	较低	较高
部署复杂度	中等	较高	较低	较高
适合任务类型	长文档问答、技术手册解析、PDF 理解	开放域问答、复杂推理、信息分散的知识场景	高并发应用、资源受限部署	多跳推理、实体消歧、专业领域问答

3 RAG 评估与开源项目

随着 RAG 技术在知识问答、智能对话等任务中得到广泛应用，如何对 RAG 的性能评估也是实践中的关键问题。在本章节中，系统介绍了常用的基准和数据集、评价指标、以及具有代表性的开源项目。

3.1 基准和数据集

当前的基准和数据集为评估 RAG 系统提供了重要依据，尽管部分数据集并非专为 RAG 设计，但它们被广泛用于评测 RAG 系统检索、推理和生成能力在多种场景下的表现。通过提供结构化的任务形式和标准化的评估指标，基准在推动 RAG 系统评估的规范化方面发挥了关键作用。同时，高质量的数据集对于全面测试 RAG 系统的检索、推理和生成组件的性能至关重要。

当前主流的 RAG 评估基准涵盖多样化的任务类型与领域，为系统性能的全面评测提供了坚实基础，包括以下这些：

BEIR^[54] (Benchmarking Information Retrieval)：一个多功能信息检索基准，旨在评估各种信息检索任务的嵌入模型，涵盖生物信息学、金融和问答等不同领域的 17 个数据集。

MS MARCO^[55] (Microsoft Machine Reading Comprehension)：专注于段落排序和问题任务，被广泛用于 RAG 系统中的密集检索评测。

TREC^[56] (Text REtrieval Conference, Deep Learning Track)：为文档检索提供数据集，强调检索环节中排名模型的质量。

MuSiQue^[57] (Multihop Sequential Questioning)：跨多个文档的多跳推理基准，强调从分散的上下文中检索和整合信息的重要性。

2WikiMultihopQA^[58]：针对两篇维基百科文章的多跳 QA 任务设计的数据集，评估跨多个来源连接知识的能力。

HotpotQA^[59]：多跳 QA 基准，需要在互连的上下文上进行检索和推理，非常适合评估复杂的 RAG 工作流。

RAGBench^[60]：大规模的、可解释的基准测试，具有跨越行业领域的 100,000 个示例，提供可操作的 RAG 指标的跟踪评估框架。

此外表 2 汇总了面向 RAG 下游任务评估的一些关键数据集。

表 2 RAG 评估数据集

Table 2 RAG Evaluation Dataset		
分类	任务类型	数据集
QA	Single-hop QA	Natural Questions (NQ) ^[61] , TriviaQA ^[62] , SQuAD ^[63] , Web Questions (WebQ) ^[64] , PopQA ^[65] , MS MARCO ^[55]
	Multi-hop QA	MuSiQue ^[57] , 2WikiMultiHopQA ^[58] , HotpotQA ^[59]
	Long-form QA	ELI5 ^[66] , NarrativeQA(NQA) ^[67] , ASQA ^[68] , QMSum ^[69]
	Domain-specific QA	Qasper ^[70] , COVID-QA ^[71] , CMB/MMCU Medical ^[72]
	Multi-choice QA	QuALITY ^[73] , CommonsenseQA ^[74]
Graph-based QA	Graph QA	GraphQA ^[75]
	Event Argument Extraction	WikiEvent ^[76] , RAMS ^[77]
Dialog	Open-domain Dialog	Wizard of Wikipedia (WoW) ^[78]
	Personalized Dialog	KBP ^[79] , DuleMon ^[80]
	Task-oriented Dialog	CamRest ^[81]
Summarization	Text Summarization	WikiASP ^[82] , XSum ^[83]
	Long-form Summarization	NarrativeQA (NQA) ^[67] , QMSum ^[69]
	Language Understanding	WikiText-103 ^[61]
Others	Fact Checking/Verification	FEVER ^[84] , PubHealth ^[85]
	Strategy QA	StrategyQA ^[86]

3.2 评价指标

本节将介绍几种常用的评估 RAG 性能的指标。这些指标可以衡量 RAG 系统在响应查询或生成答案时的相关性、准确性、鲁棒性。以下是各种指标的详细介绍与计算方式。

1、精确匹配 (Exact Match, EM)

EM 用于衡量模型输出与标准答案之间的一致性，是 RAG 一种严格的评估标准。由以下公式所示：

$$EM = \begin{cases} 0 \\ 1 \end{cases} \quad (1)$$

在开放域问题回答任务中，当用户提问时，如果模型生成的答案与标准答案完全匹配，则 EM 得分为 1，否则得分即为 0。

2、准确率(Accuracy, ACC)

准确率用于衡量模型整体预测正确性。它是最直观的整体性能指标。ACC 可以用来衡量检索到的文档与问题的相关性，以及生成的答案与标准答案的匹配度。

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (2)$$

其中，TP 表示正类被正确预测为正；TN 表示负类被正确预测为负；FP 表示负类被错误预测为正；FN 表示正类被错误预测为负。

3、精确率(Precision, Prec)

Prec 用于衡量模型在检索结果中返回的相关信息所占的比例。

$$Precision = \frac{TP}{TP + FP} \quad (3)$$

4、召回率(Recall)

召回率衡量系统从所有真实相关文档中成功检索出的比例。

$$Recall = \frac{TP}{TP + FN} \quad (4)$$

5、F1 分数

F1 分数是精确率 (Precision) 和召回率 (Recall) 的调和平均，用来衡量模型在兼顾查准率与查全率之间的综合性能。

由 Precision 和 Recall 的计算公式得出 F1 分数。

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall} \quad (5)$$

6、平均倒数排名 (Mean Reciprocal Rank, MRR)

MRR 关注第一个相关文档在检索结果中的排序位置，定义为所有查询的平均倒数排名，它强调“快速命中关键数据”。MRR 数值越大，说明相关文档在检索结果中排名越靠前；反之则越靠后。

$$MRR = \frac{1}{Q} \sum_{q \in Q} \frac{1}{rank_q} \quad (6)$$

其中 $rank_q$ 表示查询 q 的第一个相关文档在检索结果中的排名；若未检索到相关文档，该项记为 0， Q 是查询的总量。

7、排名质量 (Normalized Discounted Cumulative Gain, NDCG)

NDCG 是一种同时考虑相关性等级和排序位置的排序评估指标。其核心思想是：高相关性文档在更靠前的位置，会获得更高的收益；而相同相关性的文档，排名位置如果靠后，其贡献应当被折扣。NDCG 的值范围从 0 到 1，值越高表示排序越接近理想状态。计算公式如下：

$$DCG@k = \sum_{i=1}^k \frac{2^{rel_i} - 1}{\log_2(i+1)} \quad (7)$$

其中， rel_i 表示第 i 个检索结果的相关性等级， k 表示检索结果数量。为了消除不同查询之间相关文档数量和分布差异带来的影响，通常对 DCG 进行归一化，得到 NDCG。IDCG 表示理想排序下的 DCG。

$$NDCG@k = \frac{DCG@k}{IDCG@k} \quad (8)$$

8、BLEU(Bilingual Evaluation Understudy)

BLEU 是一种基于 n -gram 匹配的自动化文本生成评估指标，最初用于机器翻译评测，该指标通过计算生成文本与参考文本之间不同长度 n -gram 的重合比例来衡量生成内容的准确性。

$$BLEU = BP \bullet \exp\left(\sum_{n=1}^N w_n \log p_n\right) \quad (9)$$

其中， p_n 表示 n -gram 精确率， w_n 是权重（通常平均分配），BP 表示长度惩罚(Brevity Penalty)，防止生成文本过短来获得较高分数。

9、METEOR(Metric for Evaluation of Translation with Explicit Ordering)

METEOR 是一种在 n -gram 匹配基础上引入语义对齐机制的生成评估指标，该指标通过词形还原、同义词匹配等方式对生成文本与参考文本

进行对齐。相较 BLEU 更加关注语义一致性。

$$METEOR = F_{\alpha} \bullet (1 - Penalty) \quad (10)$$

其中，

$$F_{\alpha} = \frac{PR}{\alpha P + (1 - \alpha)R} \quad (11)$$

P 和 R 分别表示基于对齐后的精确率与召回率， α 为平衡参数，Penalty 用于惩罚碎片化严重、词序不合理的匹配结果。

3.3 RAG 开源项目

针对日益深入的 RAG 研究，RAG 框架为实践提供了支持。以下工具和框架为开发代理 RAG 系统提供了强大的支持，解决了现实世界应用程序的复杂需求。表 3 选取了 8 种主流的 RAG 开源项目，并说明了每个框架都有独特的应用场景。

表 3 RAG 开源框架

Table 3 RAG open source framework		
框架	项目地址	简介
AnythingLLM	https://github.com/Mintplex-Labs/anything-llm	开源全栈 AI 客户端，支持文本、图像、音频多模态输入，提供 Web UI 与多模型集成。
RAGFlow	https://github.com/infiniflow/ragflow	基于深度文档理解构建的开源 RAG 引擎，擅长处理含表格、图像和复杂版式的专业文档。
Dify	https://github.com/langgenius/dify	面向开发者的 LLM 应用平台，支持 RAG、Agent 与可视化 workflow 编排。
FastGPT	https://github.com/labring/FastGPT	轻量级 RAG 框架，提供可视化流程编排与 API 模型管理。
Langchain-Chatchat	https://github.com/chatchat-space/Langchain-Chatchat	基于 LangChain 的聊天型 RAG 系统，支持多轮对话交互。
ChatGPT Atlas	https://chatgpt.com/zh-Hans-CN/atlas	OpenAI 发布的首款 AI 原生浏览器，将 RAG 与实时网页浏览深度融合，并支持 AI 代理任务。
Microsoft GraphRAG	https://github.com/microsoft/graphrag	基于知识图谱的 RAG 框架，通过实体与关系图增强多跳推理能力。
LightRAG	https://github.com/HKUDS/lightRAG	轻量级、高性能 RAG 框架，支持低延迟检索与增量知识库更新。

AnythingLLM 是一个面向个人和企业用户的零代码 RAG 应用平台，它提供图形化界面并支持文本、图像和音频等多模态交互形式。AnythingLLM 同时支持本地运行与远程部署，

具备多用户管理、工作区隔离、丰富文档格式兼容以及灵活的 API 集成能力；其默认采用本地数据存储策略，在提升系统可控性的同时有效保

障了数据隐私与安全性。该框架非常适合快速搭建内部知识库或个人智能助手。

RAGFlow 由 InfiniFlow 团队开发, 专注于深度文档理解与可信问答。该框架采用 OCR、版面分析和表格识别技术, 能够从复杂非结构化数据 (如文本、图片、表格) 中精准提取关键信息, 并通过多路召回策略和引用原文链接实现精确到原文位置的可信生成。RAGFlow 在金融、法律、医疗等对准确性要求严苛的领域具有显著优势, 同时也广泛适用于企业知识管理和个人学习研究场景。

Dify 是一个面向开发者的 LLM 应用构建与部署平台, 该框架通过可视化界面, 让开发者可以灵活配置数据处理、检索策略 (向量/关键词/混合)、上下文压缩、重排序等模块, 并支持交互控制、缓存优化和性能监控。Dify 兼顾易用性与扩展性, 原生态集成了 RAG、Agent 和工作流编排能力, 适合构建产品级 AI 应用, 如智能客服、企业助手或 SaaS 服务。

FastGPT 是一个专为问答和对话任务设计的轻量级、低成本的 RAG 框架, 其特点是快速部署与高效运行。该框架提供可视化工作流, 清晰展示问题到答案的路径, 便于调试; 并通过 API 统一管理各类大模型与嵌入服务; 此外还内置搜索测试、引用修改及完整对话预览等调试工具, 提升其开发效率和用户体验。该项目架构简洁、资源占用低, 特别适合中小企业在有限算力下快速上线知识问答系统。

Langchain-Chatchat 是一个基于 LLM 与 Langchain 构建的高度中文优化的开源 RAG 项目。工作流程通过加载文件、文本分割、向量化处理及匹配最相似的文本片段来生成上下文丰富的回答。该系统支持灵活选择 LLM、向量数据库, 提供 WebUI、API 和命令行交互方式, 具备

多轮对话记忆与文档问答能力, 广泛应用于高校教学、科研实验及中文私有知识库建设。

ChatGPT Atlas 是 OpenAI 于 2025 年 10 月发布的首款 AI 原生浏览器, 它的核心是将 RAG 功能深度集成到浏览器操作的每一个环节。它不像传统 RAG 系统那样依赖静态知识库, 而是将用户当前打开的网页内容、浏览历史和选中的文本作为动态、实时的检索源。此外, 该浏览器还拥有代理模式, 能够授权 AI 自动跨网页执行多步骤任务 (如信息调研)。

Microsoft GraphRAG 是微软推出的一种基于知识图谱的 RAG 框架。该框架能从文本中自动提取实体与关系, 构成结构化的知识图谱, 并进一步通过图层次聚类、社区检测与摘要生成等机制, 对文本数据进行组织和抽象, 从而支持基于图结构的全局和局部搜索, 在复杂、多跳推理场景下能显著提升回答准确性。该方法已在企业级私有知识问答、技术文档分析等场景得到广泛应用。

LightRAG 是一种针对基于知识图谱的 RAG 框架提出的极简、高性能的轻量级 RAG 框架。其在检索阶段采用双层检索机制, 一层针对具体实体和局部信息进行细粒度检索, 另一层针对更抽象的全局主题进行高层次检索; 同时结合图结构与向量表示实现高效关联匹配。LightRAG 还具备增量更新机制, 能够在知识库动态更新时无需重建整个索引就能融合新数据。该框架遵循“够用即止”的设计理念, 非常适合移动端、边缘设备或对响应速度敏感的实时问答服务。

4 RAG 应用

在本节中, 我们将系统介绍 RAG 的代表性应用。具体而言, 我们从下游任务和垂直领域两个角度展开。这两个角度分别体现了 RAG 在通用任务场景与专业知识领域的价值, 有助于从广度和深度两个维度全面理解其应用潜力。从下游

任务来看, RAG 主要被应用于推荐系统、软件工程等通用任务, 该角度的研究主要体现了 RAG 在通用任务中的普适价值与跨任务迁移能力。从垂直领域角度来看, RAG 在生物、金融等高度依赖专业知识的领域展现出应用潜力, 这类场景往往要求对领域知识进行精确、权威的调用, 而单纯依赖预训练大模型难以满足需求。与下游任务相比, 垂直领域更强调专业性与可靠性, 该角度的研究更多体现了 RAG 在应对专业化、知识密集型任务中的优势。

4.1 下游任务

RAG 在下游任务中应用十分广泛, 例如推荐系统和软件工程。在推荐系统中, 传统方法主要依赖于用户的历史行为数据来建模用户偏好并生成个性化推荐, 所以当用户行为数据稀疏时, 推荐系统难以提供准确的结果。由于 RAG 整合外部知识的特点可以弥补这一问题, 所以将 RAG 应用于推荐系统具有巨大的潜力, 因为这样能更好地模拟用户的兴趣偏好, 从而为用户提供更合理、可解释、更个性化地推荐结果。在软件工程领域, 通过将自然语言需求与外部知识库 (如代码文档、开发手册或开源仓库) 相结合, RAG 能够帮助开发者快速定位关键信息, 降低学习和探索成本, 同时提升软件开发的效率与质量。

例如在推荐系统领域, 已经有多种框架将 RAG 技术应用其中, 显著改进了传统推荐系统在冷启动、长尾推荐等场景的性能。RaRS^[87]框架是一个简单的检索增强推荐模型, 通过理解用户隐式偏好 (如产品评论、社交媒体帖子) 来提供更精确的推荐, 有效解决了传统推荐系统中的冷启动问题。该框架可广泛应用于内容流媒体、电子商务产品等领域, 为用户提供更个性化的推荐。RevCore^[88]是一种结合外部评论信息的对话推荐系统, 该系统根据用户对话上下文中的物品

提及和情感极性, 从评论数据库中检索匹配的用户评论, 然后将用户评论信息无缝整合到对话历史中, 该框架可以从评论丰富的物品信息中学习用户偏好, 提高推荐和回复的质量。CoRAL^[89]框架通过强化学习逐步优化检索策略, 找到最小但充分的协同信息集 (用户-物品交互), 从而引导 LLM 理解用户-物品交互模式, 并生成推荐预测, 该框架在长尾物品推荐等场景表现良好。

RAG 的兴起影响了软件工程的许多方面。

例如在代码生成领域, REDCODER^[90]框架受开发者行为启发, 从数据库中检索与输入 (自然语言描述或代码片段) 相关的代码或摘要, 作为代码生成或摘要模型的补充。SYNCHROMESH^[91]框架在检索阶段动态选择与用户查询描述在语义上相似的实例, 并在生成阶段使用丰富的语法和语义约束, 以此确保生成的代码的相关性和有效性。DocPrompting^[92]首先根据自然语言意图检索相关的代码文档, 然后基于自然语言意图和检索到的文档生成代码。该方法不仅适用于任何编程语言, 还可广泛应用于需要生成未见过的函数和库调用的代码生成任务。CEDAR^[93]框架基于嵌入和频率分析从大型代码示例池中检索与开发者任务的代码示例, 结合自然语言指令动态构建提示, 可应用于程序修复等场景。此外, RAG 在文本到 SQL 的语义解析和表格数据处理任务中也展现出应用潜力。Shi^[94]等人发现文本到 SQL 语义解析任务的工作主要集中在英语上, 对于其他语言的支持有限, 基于此他们提出的 XRICL 框架可以将非英语的自然语言查询翻译成英语模式的 SQL 查询, 然后为给定的查询检索相关的英语范例构建提示从而生成答案, 该框架为跨语言数据库查询提供了新的有力工具, 进一步帮助全球用户更方便访问和理解数据库。

SheetCopilot^[95]框架是一个专门为电子表格设计

的代理,能够理解自然语言形式的高级电子表格操作请求并执行操作。它在任务执行过程中会利用外部文档和错误反馈来修正不正确的操作,确保任务顺利进行。DATER^[96]框架利用 RAG 技术帮助 LLM 同时处理自然语言问题和结构化或半结构化的表格数据。

4.2 垂直领域

如果将 LLM 直接应用于垂直领域,由于缺乏领域特定知识等原因,其回答往往容易产生幻觉。但是训练专用的 LLM 在成本、数据源获取、隐私保护等方面会面临着挑战,相比之下 RAG 通过整合外部知识库提升模型能力,并可在私有部署中有效降低隐私泄露风险,所以将 RAG 应用于垂直领域成为一种可行方案,并已广泛应用于科学研究中的生物领域以及金融等高专业性行业。

由于垂直领域普遍具有高度知识密集的特性,RAG 在不同垂直领域的应用并非简单地引入外部检索模块,而是需要与领域专业知识进行深度融合。例如在生物领域,药物研发、分子发现等任务通常具有严格的科学规范,不仅需要生成结果具备准确性,还需具备明确的知识溯源与推理逻辑,以支持实验验证与后续研究。因此该领域的 RAG 设计更聚焦于对权威生物医学知识的精确检索、跨模态信息的结构化整合、还有生成过程中证据与结论之间的可对齐性。在金融分析与市场研究领域,信息的时效性和准确性会直接影响投资决策的质量。所以将 RAG 应用于金融场景时,其设计需要重点考虑实时市场数据、相关政策法规以及历史知识金融知识之间的动态协同。在数据频繁更新与严格合规的约束下,不仅要兼顾知识库的时效性、还要保证检索的高精度以及生成结果的可靠性。下文将结合具体技术框架,系统剖析 RAG 如何通过面向特定领域的针对性来优化应对上述难点。

在生物领域 RAG 已被证明有益于新物质发现,如分子和蛋白质。分子包括识别分子的性质和预测新分子,从而有利于药物发现。MolReGPT^[97]框架引入上下文少样学习策略,通过检索相似分子及其文本描述为 LLM 提供上下文学习实例,使 LLM 能够在不进行预训练和微调的情况下执行分子-描述翻译任务,该框架为分子发现和设计提供了新范式。多模态分子结构-文本模型 MoleculeSTM^[98]通过对比学习策略联合学习分子的化学结构和文本描述,在给定化学结构检索文本描述、基于文本的分子编辑和分子属性预测等任务上表现出色。RetMol^[99]是一个基于检索的可控分子生成框架,它通过检索样本分子并将其与输入分子融合,预测输入分子的最近邻居,实现无需任务特定微调的可控分子生成。BioBridge^[100]是一种参数高效的生物医学多模态学习框架,利用知识图谱学习单模态之间的转换,可以将自己呈现为一种通用检索器,帮助生物医学多模态问题的回答,并增强新药的引导生成。PromptDiff^[101]模型首先设计一个几何蛋白质-分子配体相互作用网络,检索具有高结合亲和力的配体作为提示,以引导扩散模型合成满足设计标准的配体分子。生成的分子不仅具有更真实 3D 结构,并拥有对蛋白质靶标的最先进的结合亲和力,同时保持适当的分子特性。

在高度数据驱动和信息密集型的金融领域,RAG 已被证明是增强决策的重要技术。StockChain^[102]框架结合 LLM 和构建高质量金融知识库,通过设计提示模板和利用实时市场金融新闻和报告数据,提供准确的股票趋势预测和全面的金融问答服务。张^[103]等人从可靠外部来源检索金融信息,例如新闻平台(如彭博和路透社)和社交媒体平台(如 Twitter、Reddit),为用户查询提供更丰富的背景知识,同时也为金融情感分

析领域提供了新的研究思路和技术手段。此外, 像金融这种高专业性的知识一般以 PDF 格式存储, Yepes^[104]等人提出一种超越段落级分块的方法, 通过基于文档的自然结构进行信息分块, 显著提高了 RAG 系统在财务报告问答任务上的检索准确性和问答准确性。

5 RAG 未来方向

尽管 RAG 在自然语言处理和专业领域中展现出显著潜力, 但相关研究仍处于相对早期阶段, 许多问题尚未得到充分探索。因此, 我们提出一些具有可行性的研究方向, 其中包括多模态 RAG、RAG 与 Agent 集成。多模态 RAG 能够整合文本、图像、音频等多种模态信息, 提供比单模态 RAG 更丰富的上下文信息, 所以探索多模态 RAG 有助于拓展 RAG 在现实场景的适用范围, 并提升其在高复杂度任务中的表现。将 RAG 与 Agent 集成, 可以赋予框架自主决策能力和动态知识调用能力, 使其在多轮交互、任务规划等复杂场景中表现出更高适应性, 为构建智能化、多功能的 AI 系统提供新的研究方向。

5.1 多模态 RAG

随着越来越多的 LLM 不再局限于传统的文本问答任务, 而是扩展到图像、音频、视频等多模态领域, RAG 也从最初只面向文本问答的形态逐步发展到能够处理多模态数据的框架。多模态相比单模态不仅拥有更加丰富的上下文信息, 而且各种不同模态信息的融合可以帮助 LLM 对用户查询进行更全面的理解从而提高生成质量。近年来, 随着 CLIP^[105]等跨模态对齐模型的出现, 以及 GPT-4o、Gemini、Qwen-VL 等多模态大模型的相继发布, 多模态 RAG 作为一种新兴的设计范式, 正迅速成为连接外部知识与多模态生成能力的关键桥梁。

从方法层面来看, 多模态 RAG 的创新主要集中在统一表示学习、多源异构数据处理与检索

机制三个方面。例如, MuRAG^[106]是一个支持图文联合检索与生成的端到端多模态 RAG 框架, 其核心技术是通过大规模图文训练出一个统一的多模态骨干编码器, 然后该编码器能将图像和文本统一编码为共享语义空间的稠密向量, 实现图文联合检索, 最后通过交叉注意力机制实现跨模态信息融合从而生成答案。mRAG^[107]是一个统一处理文本、表格、图像和视频的多模态 RAG 系统。它利用多模态大模型分别从 PDF 与视频中提取多模态内容, 生成语义摘要或描述, 再用多模态嵌入模型将所有数据向量化并索引至 OpenSearch。推理时, 系统跨模态检索相关片段并结合用户查询生成答案, 同时自动附带可追溯的引用来源, 集成隐私保护与安全护栏机制。SAM-RAG^[108]是一个面向多模态场景的自适应 RAG 框架, 其核心在于引入动态检索过滤机制与双重验证模块。该框架能根据图文查询自适应决定是否检索图像字幕等视觉上下文并动态调整检索文档数量; 在检索后通过一个轻量级相关性验证器过滤低质量或无关文档; 在生成答案后, 利用事实一致性校验模块评估输出与检索证据的一致性, 必要时重新生成答案。

多模态 RAG 相比于传统 RAG 能更全面理解世界, 导致更准确和更有见地的输出, 广泛应用于在医疗诊断、金融分析、智能制造、教育辅助等多个领域, 并且在更复杂、更贴近真实需求的场景中发挥出更强的作用。例如在图像领域, 2023 年 Meta AI 团队率先提出第一个检索增强的多模态 LLMRA-CM3^[109], 该模型接受的用户输入可以是文本, 图像或者二者结合, 并能根据用户需求生成符合要求的图像或者进行图像编辑等操作。BLIP-2^[110]将图像编码器和 LLM 冻结, 实现视觉到语言的跨模态对齐。该方法通过图像编码器提取图像特征, 并利用这些视觉信息作为额

外的输入来指导 LLM 的文本生成。iNLG^[111]将机器生成的图像通过视觉编码器提取特征，并将这些特征作为视觉前缀输入到 LLM 中，与文本上下文一起指导文本生成。在音频和视频领域，UEOP^[112]是一个自动化语音识别任务，它首先构建文本到语音的离线键值的外部记忆，其中音频嵌入作为键，文本嵌入作为值；然后通过查询外部记忆检索最相似的键值来辅助自动化语音识别。该方法在个性化定制场景中表现尤为突出。GSS^[113]是一个端到端语音翻译系统，它预先构建一个包含口语词汇的语音词库，在实现时它根据输入文本从语音词库检索相应的音频片段，然后使用交叉淡入技术平滑拼接处，从而实现自然流畅的语音合成。Vid2Seq^[114]是一种多模态单阶段密集视频字幕模型，通过在文本编码中引入时间令牌，能够同时预测视频的时间边界和文本描述，增强了模型对多视频信息的处理能力。

未来的 RAG 研究应更加重视不同模态之间的语义对齐，例如，将图像、音频、视频等非文本数据转化为统一的嵌入空间，以便在检索阶段实现跨模态的精确匹配与关联推理。此外由于多模态数据处理计算量大，如何优化高效索引和缓存机制也值得研究，这也是推动 RAG 的应用落地的重要方向。总体来看，RAG 正在从“单一文本驱动”向“全模态智能融合”演进，这不仅扩大了其应用边界，也对检索、推理、知识构建和系统优化提出了更高要求。

5.2 RAG 与 Agent 集成

传统的 RAG 框架虽然能够通过集成外部知识库来提升 LLM 回答的准确性，但其线性和静态的工作流这限制了它们在复杂任务中的表现，例如多步骤推理、集成深度上下文理解和迭代细化响应等方面。为缓解这些不足，将智能体 (Agent^[115]) 与 RAG 结合成为一种可行方案。

Agent 通常指能够在环境中自助感知、推理和自主执行任务的智能实体。这些代理通过多种代理模式，如反思、规划、工具使用和多智能体协作，来增强决策的灵活性和系统的适应性。在 RAG 框架中使用 Agent 可以突破上述限制，这些 Agent 利用代理设计模式反思、规划、工具使用和多代理协作来动态管理检索和生成策略，还能迭代地细化上下文理解，并通过从顺序步骤到自适应协作的多层操作结构来调整工作流。因此，将 RAG 与 Agent 集成是未来的发展趋势。

LLM 在推理时，仍然面临着信息不一致、推理方向不正确等问题。为解决这些问题，Wang^[116]等人提出将 RAG 与思维链结合的方法，利用外部知识库修正 LLM 的推理路径并增强信息一致性。与此同时，许多研究将 RAG 与 Agent 的集成，并通过引入多样化的智能体工作流程模式来优化任务执行与推理过程。例如，MAD^[117]框架设计多个能“针锋相对”的状态表达论点的智能体，并由一名智能体法官根据辩论历史决定最终解决方案。MAD 框架通过鼓励 LLM 中的发散思维，有助于提升模型在复杂推理任务上的性能。RECONCILE^[118]是一个多模型多智能体框架，它为不同 LLM 智能体开展圆桌会议。RECONCILE 通过多轮讨论、学习说服其他 LLM 智能体改进它们的答案以及采用信心加权投票机制来达成更好的共识，从而增强 LLM 智能体之间的协作推理。Debate^[119]框架受“思维社会”理论启发，提出多智能体辩论方法，多个 LLM 首先生成候选答案，然后每个模型阅读并批判其他模型的回答，并基于此更新自己的答案，经过多轮辩论达成共识。多智能体框架利用强提示帮助代理保持对上下文的敏感性，确保推理路径的准确性，优于传统的 Chain-of-Thought^[120]方法。

此外, 有许多 RAG 框架利用智能体来管理检索生成过程。Agentic RAG^[121]框架利用分层的多智能体架构, 其中主智能体协调专门的子智能体, 并将最终用户请求委托给相关的子智能体。子智能体通过使用指令调整和直接偏好优化的微调, 利用为特定时间序列任务定制的较小的预训练语言模型, 并从包含关于历史模式和趋势的知识库中检索相关提示, 以改进对新数据的预测。GeAR^[122]采用智能体的架构来管理检索过程, 支持基于查询复杂性动态选择和组合检索策略, 智能体可以自主地决定利用图扩展的检索路径来提高检索信息的相关性和准确性。

将 RAG 与 Agent 相集成能够克服传统静态工作流的限制, 提供更加个性化、实时化和上下文感知的解决方案, 并在医疗保健、金融、教育和创意产业等领域展现出变革潜力。然而 RAG - Agent 的融合仍面临诸多挑战, 例如多智能体架构的协调复杂性、系统的可扩展性以及推理过程中的延迟问题, 这些都亟需进一步研究与创新。总体而言, RAG 正在从单纯的知识增强生成逐步演进为具备智能自主决策能力的系统, 其未来发展方向将更加侧重于自主推理、动态协作与自适应优化。

6 结论

LLM 目前在广泛的任务中展现出卓越的能力, 但是在面对从未出现在预训练语料库中的领域专业知识知识密集型任务时, 往往会产生与事实不相符的回答。RAG 通过整合来自外部知识源的相关信息, 在不需要特定任务数据微调 LLM 的情况下, 使得 LLM 能够适应特定领域并减轻知识密集型任务中的幻觉。因此将 RAG 与 LLM 结合已经成为一种可行方案。本综述深入探讨了目前 RAG 框架遇到的挑战, 并以此为切入点, 不同于以往按照 RAG 的“索引-检索-生成”三阶段流程划分的方式, 而是从分块优化、

检索改进、上下文压缩和知识图谱融合四个维度对前沿技术进行了深度梳理与机制剖析, 并突出了它们各自的优势、局限性以及它们适合解决的问题类型。本综述帮助研究人员快速了解 RAG 技术演进脉络, 可以根据不同场景便于对比和选择合适的方法。实践表明目前已经有许多 RAG 框架在各种应用中取得了显著的成功, 包括推荐系统、和软件工程、科学、金融等高专业性行业。此外由于 RAG 的研究仍处于早期阶段, 我们还讨论了几个潜在研究方向, 为后续研究人员提供新的见解。

然而, 受综述视角限制, 本综述更多地聚焦于 RAG 方法在技术架构与系统框架层面的演进与设计, 对 RAG 范式在实际应用中所面临的一些根本性问题尚未展开充分深入探讨。例如, RAG 如何应对知识源本身的可靠性与统一性问题, 在本综述中未得到系统分析。事实上, RAG 系统在运行过程中高度依赖外部知识源 (文档库、数据库或网络资源), 但这些知识源在质量、时效性、覆盖范围等方面往往存在显著差异。这种不确定性不仅会直接影响系统生成内容的准确性与可信度, 构成系统性能的关键瓶颈, 还会引发对整个 RAG 范式稳健性与适用边界的进一步思考。

参考文献

- [1] Singhal K, Tu T, Gottweis J, et al. Toward expert-level medical question answering with large language models[J]. *Nature Medicine*, 2025, 31(3): 943-950.
- [2] Ji Z, Lee N, Frieske R, et al. Survey of hallucination in natural language generation[J]. *ACM computing surveys*, 2023, 55(12): 1-38.
- [3] Hu E J, Shen Y, Wallis P, et al. LoRA: Low-Rank Adaptation of Large Language Models[Z]. *arXiv*, 2021(2021-10-16).
- [4] Gekhman Z, Yona G, Aharoni R, et al. Does Fine-Tuning LLMs on New Knowledge Encourage Hallucinations?[Z]. *arXiv*, 2024(2024-10-01).
- [5] Zhai Y, Tong S, Li X, et al. Investigating the Catastrophic Forgetting in Multimodal Large Language Model Fine-Tuning[C]//*Proceedings of the Conference on Parsimony and Learning*.

- Proceedings of Machine Learning Research, 2024, 234: 202-227.
- [6] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[Z]. arXiv, 2021(2021-04-12).
 - [7] Robertson S, Zaragoza H. The Probabilistic Relevance Framework: BM25 and Beyond[J]. Foundations and Trends® in Information Retrieval, 2009, 3(4): 333-389.
 - [8] Spärck Jones K. A statistical interpretation of term specificity and its application in retrieval[J]. Journal of Documentation, 2004, 60(5): 493-502.
 - [9] Karpukhin V, Oğuz B, Min S, et al. Dense Passage Retrieval for Open-Domain Question Answering[Z]. arXiv, 2020(2020-09-30).
 - [10] Izacard G, Caron M, Hosseini L, et al. Unsupervised Dense Information Retrieval with Contrastive Learning[Z]. arXiv, 2022(2022-08-29).
 - [11] Gao Y, Xiong Y, Gao X, et al. Retrieval-augmented generation for large language models: A survey[J]. arXiv preprint arXiv:2312.10997, 2023, 2(1).
 - [12] Fan W, Ding Y, Ning L, et al. A survey on rag meeting llms: Towards retrieval-augmented large language models[C]//Proceedings of the 30th ACM SIGKDD conference on knowledge discovery and data mining. 2024: 6491-6501.
 - [13] Zhao S, Yang Y, Wang Z, et al. Retrieval augmented generation (rag) and beyond: A comprehensive survey on how to make your llms use external data more wisely[J]. arXiv preprint arXiv:2409.14924, 2024.
 - [14] Zhang Q, Chen S, Bei Y, et al. A survey of graph retrieval-augmented generation for customized large language models[J]. arXiv preprint arXiv:2501.13958, 2025.
 - [15] Singh A, Ehtesham A, Kumar S, et al. Agentic retrieval-augmented generation: A survey on agentic rag[J]. arXiv preprint arXiv:2501.09136, 2025.
 - [16] Qian H, Liu Z, Mao K, et al. Grounding Language Model with Chunking-Free In-Context Retrieval[Z]. arXiv, 2024(2024-02-15).
 - [17] Luo K, Liu Z, Xiao S, et al. BGE Landmark Embedding: A Chunking-Free Embedding Method For Retrieval Augmented Long-Context Large Language Models[Z]. arXiv, 2024(2024-02-18).
 - [18] Zhong Z, Liu H, Cui X, et al. Mix-of-Granularity: Optimize the Chunking Granularity for Retrieval-Augmented Generation[Z]. arXiv, 2025(2025-01-26).
 - [19] Duarte A V, Marques J, Graça M, et al. LumberChunker: Long-Form Narrative Document Segmentation[Z]. arXiv, 2024(2024-06-25).
 - [20] Tripathi V, Odapally T, Das I, et al. Vision-Guided Chunking Is All You Need: Enhancing RAG with Multimodal Document Understanding[Z]. arXiv, 2025(2025-07-13).
 - [21] Sheng B, Yao J, Zhang M, et al. Dynamic Chunking and Selection for Reading Comprehension of Ultra-Long Context in Large Language Models[Z]. arXiv, 2025(2025-06-03).
 - [22] Günther M, Mohr I, Williams D J, et al. Late Chunking: Contextual Chunk Embeddings Using Long-Context Embedding Models[Z]. arXiv, 2025(2025-07-07).
 - [23] Feng J, Tao C, Geng X, et al. Synergistic Interplay between Search and Large Language Models for Information Retrieval[Z]. arXiv, 2023(2023-12-12).
 - [24] Wang K, Reimers N, Gurevych I. DAPR: A Benchmark on Document-Aware Passage Retrieval[Z]. arXiv, 2024(2024-06-09).
 - [25] Jiang Z, Xu F F, Gao L, et al. Active Retrieval Augmented Generation[Z]. arXiv, 2023(2023-10-22).
 - [26] [19] Jeong S, Baek J, Cho S, et al. Adaptive-RAG: Learning to Adapt Retrieval-Augmented Large Language Models through Question Complexity[Z]. arXiv, 2024(2024-03-28).
 - [27] Asai A, Wu Z, Wang Y, et al. Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection[Z]. arXiv, 2023(2023-10-17).
 - [28] Wang L, Yang N, Huang X, et al. SimLM: Pre-training with Representation Bottleneck for Dense Passage Retrieval[Z]. arXiv, 2023(2023-05-12).
 - [29] Zhang L, Yu Y, Wang K, et al. ARL2: Aligning Retrievers for Black-box Large Language Models via Self-guided Adaptive Relevance Labeling[Z]. arXiv, 2024(2024-06-04).
 - [30] Ke Z, Kong W, Li C, et al. Bridging the Preference Gap between Retrievers and LLMs[Z]. arXiv, 2024(2024-02-20).
 - [31] Cheng X, Luo D, Chen X, et al. Lift Yourself Up: Retrieval-augmented Text Generation with Self Memory[Z]. arXiv, 2023(2023-12-23).
 - [32] Guu K, Lee K, Tung Z, et al. REALM: Retrieval-Augmented Language Model Pre-Training[Z]. arXiv, 2020(2020-02-10).
 - [33] Cheng X, Wang X, Zhang X, et al. xRAG: Extreme Context Compression for Retrieval-augmented Generation with One Token[Z]. arXiv, 2024(2024-12-09).
 - [34] Chang C-Y, Jiang Z, Rakesh V, et al. MAIN-RAG: Multi-Agent Filtering Retrieval-Augmented Generation[Z]. arXiv, 2024(2024-12-31).
 - [35] Zhu K, Feng X, Du X, et al. An Information Bottleneck Perspective for Effective Noise Filtering on Retrieval-Augmented Generation[Z]. arXiv, 2024(2024-07-04).
 - [36] Jiang H, Wu Q, Lin C-Y, et al. LLMlingua: Compressing Prompts for Accelerated Inference of Large Language Models[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 13358-13376.
 - [37] Pan Z, Wu Q, Jiang H, et al. LLMlingua-2: Data Distillation for Efficient and Faithful Task-Agnostic Prompt Compression[Z]. arXiv, 2024(2024-08-12).
 - [38] Wang Z, Araki J, Jiang Z, et al. Learning to

- Filter Context for Retrieval-Augmented Generation[Z]. arXiv, 2023(2023-11-14).
- [39] Xu F, Shi W, Choi E. RECOMP: Improving Retrieval-Augmented LMs with Compression and Selective Augmentation[Z]. arXiv, 2023(2023-10-06).
- [40] Shi K, Sun X, Li Q, et al. Compressing Long Context for Enhancing RAG with AMR-based Concept Distillation[Z]. arXiv, 2024(2024-05-06).
- [41] Jung D, Liu Q, Huang T, et al. Familiarity-Aware Evidence Compression for Retrieval-Augmented Generation[Z]. arXiv, 2024(2024-12-17).
- [42] Rau D, Wang S, Dêean H, et al. Context Embeddings for Efficient Answer Generation in RAG[Z]. arXiv, 2024(2024-10-29).
- [43] Han H, Wang Y, Shomer H, et al. Retrieval-Augmented Generation with Graphs (GraphRAG)[Z]. arXiv, 2025(2025-01-08).
- [44] Liang L, Bo Z, Gui Z, et al. Kag: Boosting llms in professional domains via knowledge augmented generation[C]//Companion Proceedings of the ACM on Web Conference 2025. 2025: 334-343.
- [45] Guan X, Liu Y, Lin H, et al. Mitigating large language model hallucinations via autonomous knowledge graph-based retrofitting[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024, 38(16): 18126-18134.
- [46] Lairgi Y, Moncla L, Cazabet R, et al. iText2KG: Incremental Knowledge Graphs Construction Using Large Language Models[Z]. arXiv, 2024(2024-09-05).
- [47] Cao Y, Han S, Gao Z, et al. GraphInsight: Unlocking Insights in Large Language Models for Graph Structure Understanding[Z]. arXiv, 2024(2024-12-16).
- [48] Zhou C, Wang Z, Chen S, et al. Large Language Models based Graph Convolution for Text-Attributed Networks[J]. 2024.
- [49] Cheng K, Ahmed N K, Willke T, et al. Structure Guided Prompt: Instructing Large Language Model in Multi-Step Reasoning by Exploring Graph Structure of the Text[Z]. arXiv, 2024(2024-02-20).
- [50] Xu D, Li X, Zhang Z, et al. Harnessing Large Language Models for Knowledge Graph Question Answering via Adaptive Multi-Aspect Retrieval-Augmentation[Z]. arXiv, 2025(2025-01-06).
- [51] Li S, He Y, Guo H, et al. GraphReader: Building Graph-based Agent to Enhance Long-Context Abilities of Large Language Models[Z]. arXiv, 2024(2024-11-05).
- [52] Anonymous. Insight at the right spot: Provide decisive subgraph information to Graph LLM with reinforcement learning[J]. Information Fusion, 2025, 117: 102860.
- [53] Liu H, Wang S, Zhu Y, et al. Knowledge Graph-Enhanced Large Language Models via Path Selection[C]//Findings of the Association for Computational Linguistics: ACL 2024. Bangkok, Thailand: Association for Computational Linguistics, 2024: 6311-6321.
- [54] Thakur N, Reimers N, Rüchlé A, et al. Beir: A heterogenous benchmark for zero-shot evaluation of information retrieval models[J]. arXiv preprint arXiv:2104.08663, 2021.
- [55] Nguyen T, Rosenberg M, Song X, et al. Ms marco: A human-generated machine reading comprehension dataset[J]. 2016.
- [56] Craswell N, Mitra B, Yilmaz E, et al. Overview of the TREC 2022 deep learning track[J]. arXiv preprint arXiv:2507.10865, 2025.
- [57] Trivedi H, Balasubramanian N, Khot T, et al. 🎵 MuSiQue: Multihop Questions via Single-hop Question Composition[J]. Transactions of the Association for Computational Linguistics, 2022, 10: 539-554.
- [58] Ho X, Nguyen A K D, Sugawara S, et al. Constructing a multi-hop qa dataset for comprehensive evaluation of reasoning steps[J]. arXiv preprint arXiv:2011.01060, 2020.
- [59] Yang Z, Qi P, Zhang S, et al. HotpotQA: A dataset for diverse, explainable multi-hop question answering[C]//Proceedings of the 2018 conference on empirical methods in natural language processing. 2018: 2369-2380.
- [60] Friel R, Belyi M, Sanyal A. Ragbench: Explainable benchmark for retrieval-augmented generation systems[J]. arXiv preprint arXiv:2407.11005, 2024.
- [61] Kwiakowski T, Palomaki J, Redfield O, et al. Natural questions: a benchmark for question answering research[J]. Transactions of the Association for Computational Linguistics, 2019, 7: 453-466.
- [62] Joshi M, Choi E, Weld D S, et al. Triviaqa: A large scale distantly supervised challenge dataset for reading comprehension[J]. arXiv preprint arXiv:1705.03551, 2017.
- [63] Rajpurkar P, Zhang J, Lopyrev K, et al. Squad: 100,000+ questions for machine comprehension of text[J]. arXiv preprint arXiv:1606.05250, 2016.
- [64] Berant J, Chou A, Frostig R, et al. Semantic parsing on freebase from question-answer pairs[C]//Proceedings of the 2013 conference on empirical methods in natural language processing. 2013: 1533-1544.
- [65] Mallen A, Asai A, Zhong V, et al. When not to trust language models: Investigating effectiveness of parametric and non-parametric memories[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2023: 9802-9822.
- [66] Fan A, Jernite Y, Perez E, et al. ELI5: Long form question answering[J]. arXiv preprint arXiv:1907.09190, 2019.
- [67] Kočický T, Schwarz J, Blunsom P, et al. The narrativeqa reading comprehension challenge[J]. Transactions of the Association for Computational Linguistics, 2018, 6: 317-328.
- [68] Stelmakh I, Luan Y, Dhingra B, et al. ASQA:

- Factoid questions meet long-form answers[J]. arXiv preprint arXiv:2204.06092, 2022.
- [69] Zhong M, Yin D, Yu T, et al. QMSum: A new benchmark for query-based multi-domain meeting summarization[C]//Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2021: 5905-5921.
- [70] Dasigi P, Lo K, Beltagy I, et al. A dataset of information-seeking questions and answers anchored in research papers[J]. arXiv preprint arXiv:2105.03011, 2021.
- [71] Möller T, Reina A, Jayakumar R, et al. COVID-QA: A question answering dataset for COVID-19[C]//Proceedings of the 1st Workshop on NLP for COVID-19 at ACL 2020. 2020.
- [72] Wang X, Chen G, Dingjie S, et al. Cmb: A comprehensive medical benchmark in chinese[C]//Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). 2024: 6184-6205.
- [73] Pang R Y, Parrish A, Joshi N, et al. QuALITY: Question answering with long input texts, yes![C]//Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2022: 5336-5358.
- [74] Talmor A, Herzig J, Lourie N, et al. Commonsenseqa: A question answering challenge targeting commonsense knowledge[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). 2019: 4149-4158.
- [75] He X, Tian Y, Sun Y, et al. G-retriever: Retrieval-augmented generation for textual graph understanding and question answering[J]. Advances in Neural Information Processing Systems, 2024, 37: 132876-132907.
- [76] Li S, Ji H, Han J. Document-level event argument extraction by conditional generation[J]. arXiv preprint arXiv:2104.05919, 2021.
- [77] Ebner S, Xia P, Culkin R, et al. Multi-sentence argument linking[C]//Proceedings of the 58th annual meeting of the association for computational linguistics. 2020: 8057-8077.
- [78] Dinan E, Roller S, Shuster K, et al. Wizard of wikipedia: Knowledge-powered conversational agents[J]. arXiv preprint arXiv:1811.01241, 2018.
- [79] Wang H, Hu M, Deng Y, et al. Large language models as source planner for personalized knowledge-grounded dialogue[J]. arXiv preprint arXiv:2310.08840, 2023.
- [80] Xu X, Gou Z, Wu W, et al. Long time no see! open-domain conversation with long-term persona memory[J]. arXiv preprint arXiv:2203.05797, 2022.
- [81] Wen T H, Gasic M, Mrkšić N, et al. Conditional generation and snapshot learning in neural dialogue systems[C]//Proceedings of the 2016 conference on empirical methods in natural language processing. 2016: 2153-2162.
- [82] Hayashi H, Budania P, Wang P, et al. Wikiasp: A dataset for multi-domain aspect-based summarization[J]. Transactions of the Association for Computational Linguistics, 2021, 9: 211-225.
- [83] Narayan S, Cohen S B, Lapata M. Don't give me the details, just the summary! topic-aware convolutional neural networks for extreme summarization[J]. arXiv preprint arXiv:1808.08745, 2018.
- [84] Thorne J, Vlachos A, Christodoulopoulos C, et al. FEVER: a large-scale dataset for fact extraction and VERification[J]. arXiv preprint arXiv:1803.05355, 2018.
- [85] Kotonya N, Toni F. Explainable automated fact-checking for public health claims[J]. arXiv preprint arXiv:2010.09926, 2020.
- [86] Geva M, Khashabi D, Segal E, et al. Did aristotle use a laptop? a question answering benchmark with implicit reasoning strategies[J]. Transactions of the Association for Computational Linguistics, 2021, 9: 346-361.
- [87] Di Palma D. Retrieval-augmented Recommender System: Enhancing Recommender Systems with Large Language Models [C]//Proceedings of the 17th ACM Conference on Recommender Systems. Singapore: Association for Computing Machinery, 2023: 1-8.
- [88] Lu Y, Bao J, Song Y, et al. RevCore: Review-augmented Conversational Recommendation[Z]. arXiv, 2021(2021-06-02).
- [89] Wu J, Chang C-C, Yu T, et al. CoRAL: Collaborative Retrieval-Augmented Large Language Models Improve Long-tail Recommendation[Z]. arXiv, 2024(2024-03-11).
- [90] Parvez M R, Ahmad W U, Chakraborty S, et al. Retrieval Augmented Code Generation and Summarization[Z]. arXiv, 2021(2021-09-10).
- [91] Poesia G, Polozov O, Le V, et al. Synchromesh: Reliable code generation from pre-trained language models[Z]. arXiv, 2022(2022-01-26).
- [92] Zhou S, Alon U, Xu F F, et al. DocPrompting: Generating Code by Retrieving the Docs[Z]. arXiv, 2023(2023-02-18).
- [93] Nashid N, Sintaha M, Mesbah A. Retrieval-Based Prompt Selection for Code-Related Few-Shot Learning[C]//2023 IEEE/ACM 45th International Conference on Software Engineering (ICSE). 2023: 2450-2462.
- [94] Shi P, Zhang R, Bai H, et al. XRICL: Cross-lingual Retrieval-Augmented In-Context Learning for Cross-lingual Text-to-SQL Semantic Parsing[C]//Findings of the Association for Computational Linguistics: EMNLP 2022. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, 2022: 5248-5259.

- [95] Li H, Su J, Chen Y, et al. SheetCopilot: Bringing Software Productivity to the Next Level through Large Language Models[Z]. arXiv, 2023(2023-10-30).
- [96] Ye Y, Hui B, Yang M, et al. Large Language Models are Versatile Decomposers: Decompose Evidence and Questions for Table-based Reasoning[Z]. arXiv, 2023(2023-04-27).
- [97] Li J, Liu Y, Fan W, et al. Empowering Molecule Discovery for Molecule-Caption Translation with Large Language Models: A ChatGPT Perspective[J]. IEEE Transactions on Knowledge and Data Engineering, 2024, 36(11): 6071-6083.
- [98] Liu S, Nie W, Wang C, et al. Multi-modal Molecule Structure-text Model for Text-based Retrieval and Editing[Z]. arXiv, 2024(2024-01-29).
- [99] Wang Z, Nie W, Qiao Z, et al. Retrieval-based Controllable Molecule Generation[Z]. arXiv, 2023(2023-04-24).
- [100] Wang Z, Wang Z, Srinivasan B, et al. BioBridge: Bridging Biomedical Foundation Models via Knowledge Graphs[Z]. arXiv, 2024(2024-01-19).
- [101] Yang L, Huang Z, Zhou X, et al. Prompt-based 3d molecular diffusion models for structure-based drug design[J]. 2023.
- [102] Li X, Li Z, Shi C, et al. AlphaFin: Benchmarking Financial Analysis with Retrieval-Augmented Stock-Chain Framework[Z]. arXiv, 2024(2024-03-19).
- [103] Zhang B, Yang H, Zhou T, et al. Enhancing Financial Sentiment Analysis via Retrieval Augmented Large Language Models[C]//Proceedings of the Fourth ACM International Conference on AI in Finance. New York, NY, USA: Association for Computing Machinery, 2023: 349-356.
- [104] Yepes A J, You Y, Milczek J, et al. Financial Report Chunking for Effective Retrieval Augmented Generation[Z]. arXiv, 2024(2024-03-16).
- [105] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]//International conference on machine learning. PmLR, 2021: 8748-8763.
- [106] Chen W, Hu H, Chen X, et al. Murag: Multimodal retrieval-augmented generator for open question answering over images and text[C]//Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. 2022: 5558-5570.
- [107] Drushchak N, Polyakovska N, Bautina M, et al. Multimodal Retrieval-Augmented Generation: Unified Information Processing Across Text, Image, Table, and Video Modalities[C]//Proceedings of the 1st Workshop on Multimodal Augmented Generation via Multimodal Retrieval (MAGMaR 2025). 2025: 59-64.
- [108] Zhai W. Self-adaptive Multimodal Retrieval-Augmented Generation[J]. arXiv preprint arXiv:2410.11321, 2024.
- [109] Yasunaga M, Aghajanyan A, Shi W, et al. Retrieval-Augmented Multimodal Language Modeling[Z]. arXiv, 2023(2023-06-06).
- [110] Li J, Li D, Savarese S, et al. BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models[Z]. arXiv, 2023(2023-06-15).
- [111] Zhu W, Yan A, Lu Y, et al. Visualize before you write: Imagination-guided open-ended text generation[C]//Findings of the Association for Computational Linguistics: EACL 2023. 2023: 78-92.
- [112] Chan D M, Ghosh S, Rastrow A, et al. Using External Off-Policy Speech-To-Text Mappings in Contextual End-To-End Automated Speech Recognition[Z]. arXiv, 2023(2023-01-06).
- [113] Zhao J, Haffari G, Shareghi E. Generating synthetic speech from SpokenVocab for speech translation[C]//Findings of the Association for Computational Linguistics: EACL 2023. 2023: 1975-1981.
- [114] Yang A, Nagrani A, Seo P H, et al. Vid2seq: Large-scale pretraining of a visual language model for dense video captioning[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 10714-10726.
- [115] Anonymous. Building Effective Agents [EB/OL]. 2025[2025-02-02]. <https://www.anthropic.com/research/building-effective-agents>.
- [116] Wang Z, Liu A, Lin H, et al. RAT: Retrieval Augmented Thoughts Elicit Context-Aware Reasoning in Long-Horizon Generation[Z]. arXiv, 2024(2024-03-08).
- [117] Liang T, He Z, Jiao W, et al. Encouraging Divergent Thinking in Large Language Models through Multi-Agent Debate[Z]. arXiv, 2024(2024-10-09).
- [118] Chen J, Saha S, Bansal M. Reconcile: Round-table conference improves reasoning via consensus among diverse llms[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2024: 7066-7085.
- [119] Du Y, Li S, Torralba A, et al. Improving factuality and reasoning in language models through multiagent debate[C]//Forty-first International Conference on Machine Learning. 2023.
- [120] Wei J, Wang X, Schuurmans D, et al. Chain-of-thought prompting elicits reasoning in large language models[J]. Advances in neural information processing systems, 2022, 35: 24824-24837.
- [121] Ravuru C, Sakhinana S S, Runkana V. Agentic retrieval-augmented generation for time series analysis[J]. arXiv preprint arXiv:2408.14484, 2024.
- [122] Shen Z, Diao C, Vougiouklis P, et al. GeAR: Graph-enhanced Agent for Retrieval-augmented Generation[Z]. arXiv, 2025(2025-06-22).



Wang Xinlin, born in 2003, postgraduate student, her main research interest is retrieval-augmented generation.



Li Yan, born in 1983, Ph.D., Associate Researcher, and Master's Supervisor, his main research focus is artificial intelligence for underwater robotics.



Ma Chaofan, born in 1985, Ph.D., Associate Professor, his main research focus is intelligent algorithms.



Li Shuo, born in 1970, corresponding author, Ph.D., Researcher, and Doctoral Supervisor, his main research focus is control systems for autonomous underwater vehicles.