

数据与计算发展前沿
Frontiers of Data & Computing
ISSN 2096-742X, CN 10-1649/TP

《数据与计算发展前沿》网络首发论文

题目：面向继续教育知识学习的检索增强生成关键技术研究
作者：赵贵龙，赵以霞，王闰强，何洪波
收稿日期：2026-04-21
网络首发日期：2026-06-10
引用格式：赵贵龙，赵以霞，王闰强，何洪波. 面向继续教育知识学习的检索增强生成关键技术研究[J/OL]. 数据与计算发展前沿.
<https://link.cnki.net/urlid/10.1649.tp.20260609.1607.004>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

面向继续教育知识学习的检索增强生成关键技术研究

赵贵龙^{1,2}, 赵以霞¹, 王闰强¹, 何洪波^{1*}

1. 中国科学院计算机网络信息中心, 北京 100083

2. 中国科学院大学, 北京 100049

摘要:【应用背景】继续教育知识学习场景中, 学习者问题常存在表达不规范、学习需求隐含等现象, 导致查询与检索适配性不足; 同时, 候选证据中常混入主题相关但不直接解题的片段, 影响证据筛选与回答质量。【方法】针对学习需求难以显式进入检索链路的问题, 本文提出一种学习需求感知检索增强生成方法, 构建 CASMOOC-LearnRAG 数据集, 设计学习需求感知查询重写模型 IQ-Rewriter 和双视角学习需求门控重排序模型 DVIG-Ranker, 并在统一召回框架与统一生成约束下开展端到端评测。【结论】实验结果表明, 所提方法在查询重写、重排序和端到端问答中均取得稳定提升, 能够有效提升继续教育知识学习场景下检索增强生成系统的整体性能。

关键词: 检索增强生成; 继续教育; 查询重写; 重排序; CASMOOC

Study on Key Technologies of Retrieval-Augmented Generation for Continuing Education Knowledge Learning

ZHAO Guilong^{1,2}, ZHAO Yixia¹, WANG Runqiang¹, HE Hongbo^{1*}

1. Computer Network Information Center, Chinese Academy of Sciences, Beijing 100083, China

2. University of Chinese Academy of Sciences, Beijing 100049, China

Abstract:【Application Background】In continuing education knowledge learning scenarios, learner questions often exhibit non-standard expressions and implicit learning intents, which weakens the adaptability between user queries and the retrieval process. Meanwhile, candidate evidence often contains passages that are topically relevant but do not directly answer the question, thereby affecting evidence selection and answer quality. 【Methods】To address the difficulty of explicitly incorporating learning intent into the retrieval pipeline, this study proposes a learning-intent-aware retrieval-augmented generation method. Specifically, the CASMOOC-LearnRAG dataset was constructed, an intent-aware query rewriting model, IQ-Rewriter, and a dual-view, learning-intent-gated reranking model, DVIG-Ranker, were designed, and end-to-end evaluation was conducted under a unified retrieval framework and unified generation constraints. 【Conclusion】Experimental results show that the proposed method achieves consistent improvements in query rewriting, reranking, and end-to-end question answering, and effectively enhances the overall performance of retrieval-augmented generation systems in continuing education knowledge learning scenarios.

基金项目: 中国科学院 2026 年度优质课程资源建设项目

*通信作者: 何洪波 (E-mail: hhb@cnic.cn)

Keywords: retrieval augmented-generation; continuing education; query rewriting; reranking; CASMOOC

引言

2016年,中国科学院建立了中国科学院继续教育网——CASMOOC(<https://www.casmooc.cn/>),支持全院科研人员通过多终端在线学习,促进知识更新,提升科研技能。与通用知识问答不同,科研继续教育更多围绕实验流程、方法选择、参数配置和标准理解等实际任务展开,学习者不仅需要获得答案,还需要核验证据并回看相应课程片段。因此,面向继续教育的知识服务系统应同时具备自然语言回答、证据支撑与资源定位能力^[1-6]。

近年来,大语言模型(Large Language Models, LLMs)在教育问答、学习辅助和知识服务等任务中展现出显著潜力^[7-9]。与此同时,检索增强生成(Retrieval-Augmented Generation, RAG)通过在生成阶段引入外部知识证据,为缓解通用大模型的知识滞后与事实幻觉提供了有效路径,也为课程资源的知识化组织、证据化调用与问答式访问提供了新的技术基础^[10,11]。然而,现有通用RAG方法主要面向开放域文本问答进行设计,在科研继续教育这一高度专业化、强证据依赖的场景中仍存在明显局限^[12-14]。学习者提问常有口语化、术语不规范和条件缺失等问题,导致查询与知识库表述不匹配;通用重写可能引入语义偏移或削弱关键条件;课程资源又多以长视频和转写文本存在,候选片段主题相近但解题价值差异明显,若仅依赖通用相关性排序,容易造成证据误用。

从现有系统实践看,CASMOOC平台已经引入了遵循“问题检索—文档重排序—大语言模型生成”流程的标准RAG技术体系,如图1所示,但仍面临三类瓶颈:查询表达与检索系统适配不足,通用重排序难以区分“主题相关”与“可直接回答”,领域化评测资源缺少问题、答案、证据与视频定位的统一标注。其根源在于学习需求尚未作为显式条件信号贯穿检索链路。




图1 CASMOOC 现有检索增强生成系统框架

Fig.1 Existing retrieval-augmented generation system framework of CASMOOC

基于此,本文面向CASMOOC视频课程资源,提出一种学习需求感知的检索增强生成方法,将学习需求融入“数据构建—查询优化—证据筛选—端到端验证”的链路:在查询侧通过学习需求感知重写提升可检索性,在证据侧通过双视角与学习需求门控重排序提升关键证据筛选精度,并在统一召回与生成约束下验证整体收益^[8,9]。

本文的主要工作包括以下三个方面:

(1)构建面向CASMOOC视频课程资源的知识库与CASMOOC-LearnRAG数据集,形成包含“问题—学习需求—证据—答案—时间戳”的可追溯评测样本。

(2)提出基于监督微调与直接偏好优化的学习需求感知查询重写模型IQ-Rewriter,通过学习需求约束和检索收益对齐抑制语义漂移、增强检索适配性。

(3)提出基于双视角与学习需求门控的重排序模型DVIG-Ranker,将原始查询与重写查询作为互补视角进行证据匹配,并在重排序与端到端评测中验证其有效性。

综上, 本文关注如何将学习需求作为显式条件信号引入 RAG 检索链路, 使系统围绕学习目标准确召回、筛选并呈现可验证证据, 从而提升 CASMOOC 及类似专业培训场景的知识服务能力。

1 相关研究

1.1 教育与知识学习场景中的检索增强生成研究

随着大语言模型能力提升, 教育知识服务正由关键词匹配和固定规则转向自然语言问答与多轮交互^[8,11,15,16]。RAG 通过引入外部证据, 使系统从“能够生成回答”进一步走向“能够基于证据生成回答”^[10,17]。

现有 RAG 研究多面向教材、网页或一般文档, 对继续教育中大量音视频课程资源适配不足^[10,17-19]。

CASMOOC 等平台的课程内容具有术语密集、逻辑链条长、跨片段引用频繁等特点, 学习者问题又常隐含前提、比较维度与边界条件, 因而更需要兼顾问题驱动、证据可追溯和学习需求差异的 RAG 设计。

因此, 本文将研究重点聚焦到“学习需求如何进入检索链路”这一问题上^[18,20]。

1.2 RAG 的发展: 从检索增强到检索链路优化

随着 RAG 技术发展, 研究重点已从“检索结果拼接后生成”的朴素范式, 转向检索前与检索后的链路优化^[21-24]。前者改善查询表达与检索器适配性, 后者提升候选证据纯度与排序质量, 二者分别对应“能否召回关键证据”和“能否将有用证据排在前面”的问题, 如图 2 所示, 二者共同构成了当前高级 RAG 研究的重要方向^[20,25-29]。

1.2.1 查询重写与检索前优化研究

在 RAG 系统中, 查询表达质量直接影响召回上限。为缓解用户查询与知识库表述之间的语义不匹配问题, 已有研究提出查询扩展、查询分解、子查询生成、假设性文档嵌入和大模型查询重写等检索前优化方法^[20,24,27,30]。

其中, 基于大语言模型的查询重写能够补全缺失条件并规范表达^[23,31]。但在专业继续教育场景中也可能出现术语替换、误扩展和条件弱化等问题; 同时, 通用重写并不一定符合下游检索器偏好, 容易形成“更自然但未必更好检索”的错位^[32-34]。




图 2 朴素 RAG 和高级 RAG 之间的比较

Fig.2 Comparison between naive RAG and advanced RAG

因此, 继续教育场景中的查询重写应被视为面向学习需求的检索前对齐: 事实类问题强调术语边界, 解释类问题强调因果链条, 对比类问题强调比较维度, 应用类问题强调场景条件。若重写过程不能识别这些差异, 即便提升了表面语义完整性, 也可能造成召回方向偏移。因此, 现有研究仍缺少兼顾学习需求感知与检索收益对齐的重写机制^[18]。

1.2.2 重排序与检索后优化研究

召回阶段通常难以保证最终证据质量。

在专业课程知识库中, 许多候选片段主题相近, 却未必包含关键条件或解释链条; 若缺少检索后筛选, 容易在生成阶段造成证据误用和上下文污染。为此, 重排序、上下文压缩和文档摘要等方法逐渐成为高级 RAG 的关键环节^[35-39]。

基于 Cross-Encoder 的重排序模型能够对查询与文档进行深度交互建模, 是当前常用的精排方案^[18,40,41]。但主流重排序器通常依赖单一查询, 并主要学习一般语义相关性, 较少显式考虑不同学习目标对证据结构

的差异偏好。

在继续教育知识学习中，原始查询保留用户真实约束和上下文线索，重写查询则强调术语规范与检索友好性，二者具有互补关系。若排序器只依赖其中一个视角，可能忽略细粒度限制或被扩展后的表达误导。

因此，学习型问答仍需要同时建模双查询视角与学习需求条件化融合的重排序方法，以减少“相关”与“可用”之间的错配。

1.3 现有研究不足与本文研究切入点

综合来看，现有研究在继续教育知识学习场景中仍存在三方面不足：

第一，对继续教育问题的口语化、条件缺失和学习需求隐含关注不足；第二，查询重写方法多重语言表达，少有直接面向检索收益的训练约束；第三，重排序方法多停留在单一查询视角和一般相关性建模，缺少面向学习目标的条件化证据选择机制，同时领域化评测资源也不足。

因此，本文从检索前与检索后两个环节展开协同优化：在查询侧通过学习需求感知重写抑制语义漂移并提升召回适配性，在证据侧通过双视角学习需求门控重排序提升首命中位置与证据纯度，并结合 CASMOOC-LearnRAG 数据集和统一闭环评测协议验证方法有效性。

2 方法

针对科研继续教育场景中问题表达不规范、学习需求隐含和候选证据噪声较高等挑战，本文提出学习需求驱动的双阶段 RAG 框架：在查询侧利用基于直接偏好优化（DPO）^[47]的 IQ-Rewriter 提升问题表达与检索器的匹配程度；在证据侧利用 DVIG-Ranker 提升关键证据排序质量，最终在统一召回与生成约束下完成端到端答案生成。

2.1 问题定义与总体框架

在标准检索增强生成任务中，给定用户原始查询 q_o 和外部知识库 $\mathcal{D}$ ，系统首先从 $\mathcal{D}$ 中召回一组相关文档片段，再由生成模型结合召回证据输出最终答案^[10,11,42]。形式化地，设召回阶段返回的前 K 个文档片段为：

$$\mathcal{D}_{\text{top-}K} = \{d_1, d_2, \dots, d_K\}, d_i \in \mathcal{D} \quad (1)$$

则生成模型 $G(\cdot)$ 的目标是根据查询与证据集合生成答案 $\hat{a}$ ：

$$\hat{a} = G(q_o, \mathcal{D}_{\text{top-}K}) \quad (2)$$

与通用问答场景不同，继续教育知识学习任务中的问题通常并不只是事实性检索，而是隐含着不同认知层级下的学习目标。为此，本文在标准 RAG 框架中进一步引入学习需求变量 $\mathcal{Z}$ ，并将其定义为一个离散标签集合。

$$\mathcal{Z} = \{\text{记忆, 理解, 应用, 分析, 评价, 创造}\}, z \in \mathcal{Z} \quad (3)$$

其中， $\mathcal{Z}$ 的划分参考布鲁姆认知目标分类学（Bloom's Taxonomy）^[43,44]，不同学习需求对应不同的理想证据形态与答案组织方式。例如，“记忆”类问题更关注术语、定义与属性，“分析”类问题更关注关系拆解、维度对比与逻辑链条，“应用”类问题则更强调场景条件、步骤流程与操作约束。

基于上述认识，本文将知识学习型 RAG 任务形式化为如下条件化生成过程：

$$z = C(q_o), q_r = \pi_\theta(q_o, z), \mathcal{C} = R(q_o, q_r, \mathcal{D}), \\ \mathcal{E}_K = \text{Rank}_\phi(q_o, q_r, z, \mathcal{C}), \hat{a} = G(q_o, \mathcal{E}_K) \quad (4)$$

其中， $C(\cdot)$ 表示学习需求分类器， $\pi_\theta(\cdot)$ 表示学习需求感知查询重写模型， $R(\cdot)$ 表示召回模块， $\mathcal{C}$ 为初始候选证据集合， $\text{Rank}_\phi(\cdot)$ 表示重排序模型， $\mathcal{E}_K$ 为最终输入生成器的前 K 个证据片段。

需要强调的是，本文引入学习需求并非为了单独完成一个分类任务，而是希望将其作为检索链路中的条件信号，用于指导查询重写和证据筛选两个关键环节，使系统能够围绕学习目标而非仅围绕主题相似性完成知识检索与回答生成。

表 1 给出了六类学习需求及其对应的重写策略。这里的“重写策略”并非固定模板，而是不同学习需求下查询优化的基本原则。

表 1 学习需求分类及重写策略

Table 1 Learning intent categories and corresponding rewriting strategies

问题类型	布鲁姆层级	学习目的	重写策略
基础事实查询	记忆	检索特定定义、术语或属性	术语精炼：提升术语密度，抑制无关扩展
概念阐释/概览	理解	把握知识的内涵与解释	语义补全：增加概括性约束与

		逻辑	解释性引导词
场景迁移	应用	将知识映射	场景注入：补全
关联		到具体实践	应用前提、案例
		情境	约束与环境参数
对比/结构拆解	分析	理解知识背后的深层逻辑和内在联系	维度结构化：显式加入“差异/联系/组成”维度
验证/合规质疑	评价	检验观点，进行批判性思考	多视角对齐：改写为多证据对照或局限性辨析
综合/方案设计	创造	将知识重组，生成解决新问题的方案	合成式改写：改写为任务驱动型查询，强调组件间的组合逻辑

基于上述定义，本文总体框架包含四个阶段。

第一阶段：学习需求识别。系统首先利用轻量级中文分类模型 $C(\cdot)$ （本文采用 hfl/chinese-roberta-wwm-ext）对原始查询 q_o 分类，预测其对应的学习需求标签 Z ^[45]。

第二阶段：学习需求感知查询重写。将原始查询 q_o 与学习需求标签 Z 对应的指令提示共同输入重写模型 IQ-Rewriter，生成具有更强检索适配性的重写查询 q_r 。随后，利用混合召回模块同时基于 q_o 和 q_r 进行候选召回，得到初始候选集合 $\mathcal{C}$ 。

第三阶段：双视角学习需求门控重排序。对每个候选文档 $d_i \in \mathcal{C}$ ，模型分别基于 (q_o, d_i) 与 (q_r, d_i) 提取双视角交互表示，并结合学习需求标签 Z 进行条件化门控融合，输出候选文档的最终相关性得分，进而选取前 K 个高质量证据构成集合 $\mathcal{E}_K$ 。

第四阶段：答案生成。将筛选后的证据集合 $\mathcal{E}_K$ 与原始问题 q_o 一并输入生成模型，输出最终答案 $\hat{a}$ 。

由此可见，本文方法的核心不在于简单叠加分类、重写和重排模块，而在于通过学习需求这一显式条件变量，将“查询表达—候选召回—证据筛选—答案生成”组织为一条面向学习需求的协同优化链路。

2.2 基于 DPO 的学习需求感知查询重写 (IQ-Rewriter)

在继续教育知识学习场景中，通用大模型重写虽能提升表达完整性，却可能引入术语替换、条件弱化和无关扩展，为此，本研究采用“监督微调 (SFT)^[45,46]+ 直接偏好优化 (DPO)^[47]”的两阶段训练范式构建 IQ-Rewriter，其架构如图 3 所示，该模型首先在监督微调阶段学习不同学习需求条件下的受控查询重写策略，随后在直接偏好优化阶段利用检索收益反馈对候选重写结果进行偏好对齐，从而提升重写查询对下游检索器的适配能力。




图 3 学习需求感知查询重写模型 IQ-Rewriter

Fig 3 Learning-intent-aware query rewriting model IQ-Rewriter

2.2.1 格式遵循与 SFT 阶段

SFT 阶段的目标，是让模型先学会在给定的学习需求条件下进行有控制的查询重写。具体而言，对于每个原始查询 q_o ，系统先根据分类器预测结果得到学习需求标签 Z ，再构造输入指令

$$x = [q_o; p(z)] \quad (5)$$

其中， $p(z)$ 表示由学习需求标签 Z 触发的重写提示。模型以 x 为输入，生成目标重写序列 $y = (y_1, y_2, \dots, y_{|y|})$ ，其中 y 对应重写后的查询 q_r 。

SFT 阶段采用标准的自回归交叉熵损失：

$$\mathcal{L}_{\text{SFT}}(\theta) = - \sum_{t=1}^{|y|} \log P_{\theta}(y_t | x, y_{<t}) \quad (6)$$

其中， θ 表示重写模型参数， $y_{<t}$ 表示第 t 个位置之前已生成的目标词元。通过这一阶段训练，模型能够学习“在不同学习需求约束下应如何重写查询”的基本模式。如事实类保留术语、解释类补充因果约束、应用类补充场景条件。

SFT 主要解决格式遵循与策略注入问题，但仅优化目标文本似然，不能保证重写

结果提升下游检索质量，因此还需引入检索收益偏好对齐。

2.2.2 检索收益导向的 DPO 阶段

为使重写结果服务于下游检索，本文在 SFT 基础上引入 DPO，以“是否带来更高检索收益”作为偏好依据。对于同一个输入 x ，首先利用当前策略模型采样生成多个候选重写结果：

$$\mathcal{Y}(x) = \{y_1, y_2, \dots, y_n\} \quad (7)$$

然后，将这些候选查询分别送入混合检索器，计算各自对应的检索指标。本文采用首命中位置相关指标 $MRR@K$ 来衡量候选重写的实际收益。记 $MRR@K$ 最高的候选为优选项 y_w (chosen)，收益较低的候选为弃选项 y_l (rejected)，据此构造偏好对。

在此基础上，DPO 的优化目标写为：

$$\mathcal{L}_{DPO}(\pi_\theta; x, y_w, y_l) = -\log \sigma \left(\beta \left[\log \frac{\pi_\theta(y_w | x)}{\pi_{ref}(y_w | x)} - \log \frac{\pi_\theta(y_l | x)}{\pi_{ref}(y_l | x)} \right] \right) \quad (8)$$

其中， π_θ 为当前待优化策略模型， π_{ref} 为 SFT 阶段得到的参考模型， $\sigma(\cdot)$ 为 Sigmoid 函数， β 为控制策略偏离幅度的超参数。

该目标的含义在于：若候选 y_w 相较于 y_l 带来了更高检索收益，则优化过程应提升模型生成 y_w 的相对概率，并抑制对 y_l 的偏好。这样，检索器的反馈被隐式地纳入了重写模型的参数更新之中。因此，IQ-Rewriter 的能力并非来自简单的语义扩写，而来自两层约束的协同：一方面，SFT 让模型学会在不同学习需求下进行有控制的重写；另一方面，DPO 则使模型进一步偏向生成更具检索收益的重写结果，从而在增强语义表达的同时抑制语义漂移。

2.3 基于双视角与学习需求门控的重排序

(DVIG-Ranker)

尽管 IQ-Rewriter 提升了正确证据进入候选集合的概率，但继续教育知识库中仍存在大量高相似度噪声。传统 Cross-Encoder 重排序模型若仅使用原始查询，易受术语不完整影响；若仅使用重写查询，又可能忽略原始问题中的个性化约束与细粒度线索。为此，本文提出 DVIG-Ranker。该模型同时利用原始查询 q_o 与重写查询 q_r 两种视角对候选证据进行匹配，并通过学习需求门控模块根据当前任务类型自适应地融合两种视角的表示^[48]，从而实现面向学习目标的条件

化精排，其架构如图 4 所示，模型分别从原始查询视角和重写查询视角对候选文档进行深度交互编码，并结合学习需求嵌入进行条件化门控融合，最终输出文档相关性得分，以提升关键证据的排序质量。




图 4 基于双视角与学习需求门控的重排序模型
DVIG-Ranker

Fig.4 Dual-view and learning-intent-gated reranking model DVIG-Ranker

2.3.1 双视角特征交互编码

对于任意候选文档 $d \in \mathcal{C}$ ，本文分别构造两组输入对：

$$(q_o, d), (q_r, d) \quad (9)$$

二者共享同一个深层交互编码骨干网络 $\text{Enc}(\cdot)$ (本文采用 Transformer 架构的 Cross-Encoder)，并分别提取其 [CLS] 位置的全局表示：

$$\mathbf{v}_o = \text{Enc}([q_o; d])_{[\text{CLS}]} \in \mathbb{R}^h \quad (10)$$

$$\mathbf{v}_r = \text{Enc}([q_r; d])_{[\text{CLS}]} \in \mathbb{R}^h \quad (11)$$

其中， h 为隐藏层维度。这里， $\mathbf{v}_o$ 主要保留原始查询中的个性化约束、上下文习惯与真实意图线索， $\mathbf{v}_r$ 则更偏向术语规范化、语义补全和检索友好表达。

这种“先分别深度交互，再进行后融合”的策略，避免了直接拼接多个查询可能带来的信息混杂，使两种视角都能在 token 级别与文档进行充分对齐，从而保留其互补性。

2.3.2 基于多头注意力的学习需求门控

不同学习需求下，模型对原始查询与重写查询的依赖程度并不相同。例如，基础事实类问题可能更依赖术语精炼后的重写视角，而对比分析类问题则更需要原始提问中

隐含的比较对象和约束条件。为此，本文设计学习需求条件化门控模块（Learning Intent Gating），使模型能够根据当前学习需求动态调整两种视角的融合方式。

首先，将学习需求标签 z 映射为嵌入向量：

$$\mathbf{v}_z = \text{Emb}(z) \in \mathbb{R}^h \quad (12)$$

然后，将双视角表示堆叠为视图序列

$$\mathbf{V} = \begin{bmatrix} \mathbf{V}_o \\ \mathbf{V}_r \end{bmatrix} \in \mathbb{R}^{2 \times h} \quad (13)$$

以学习需求嵌入 $\mathbf{v}_z$ 作为 Query，以双视角特征 $\mathbf{V}$ 作为 Key 和 Value，通过多头交叉注意力聚合得到上下文表示^[49]：

$$\mathbf{v}_{\text{ctx}} = \text{MultiHeadAttn}(\mathbf{v}_z, \mathbf{V}, \mathbf{V}) \quad (14)$$

在此基础上，利用两个可学习函数 $f_1(\cdot)$ 和 $f_2(\cdot)$ 生成针对两种视角的维度级权重分数，再通过二元 Softmax 获得归一化门控权重：

$$[\mathbf{w}_o, \mathbf{w}_r] = \text{Softmax}([f_1(\mathbf{v}_{\text{ctx}}), f_2(\mathbf{v}_{\text{ctx}})]) \quad (15)$$

其中， $\mathbf{w}_o, \mathbf{w}_r \in \mathbb{R}^h$ ，且对任意维度 k 均满足

$$\mathbf{w}_o^{(k)} + \mathbf{w}_r^{(k)} = 1 \quad (16)$$

最终融合表示定义为：

$$\mathbf{v}_{\text{fused}} = \text{LayerNorm}(\mathbf{v}_z + \mathbf{w}_o \odot \mathbf{v}_o + \mathbf{w}_r \odot \mathbf{v}_r) \quad (17)$$

其中， $\odot$ 表示 Hadamard 乘积。该设计的关键在于，模型并非对两种视角赋予全局固定权重，而是允许在不同特征维度上动态判断“当前更应相信原始查询，还是更应相信重写查询”。

2.3.3 多任务联合优化

在得到融合表示 $\mathbf{v}_{\text{fused}}$ 后，本文通过多层感知机（MLP）将其映射为候选文档的最终相关性得分：

$$s(q_o, q_r, z, d) = \text{MLP}(\mathbf{v}_{\text{fused}}) \quad (18)$$

为同时优化排序精度与双视角鲁棒性，本文设计了包含主任务损失与辅助任务损失的联合优化目标。

（1）重排序对比损失

给定一个正样本 d^+ 和 L 个负样本 $\{d_j^-\}_{j=1}^L$ ，采用基于 InfoNCE 的排序对比损失^[50,51]：

$$\mathcal{L}_{\text{rank}} = -\log \frac{\exp\left(\frac{s^+}{\tau}\right)}{\exp(s^+/\tau) + \sum_{j=1}^L \exp(s_j^-/\tau)} \quad (19)$$

其中， $s^+ = s(q_o, q_r, z, d^+)$ ， $s_j^- = s(q_o, q_r, z, d_j^-)$ ， τ 为温度超参数。该损失鼓励模型将真正相关的证据片段排在前面，并与

负样本拉开分数差距。

（2）语义辅助对齐损失

虽然重写查询 q_r 提供了更规范的表达，但也可能引入一定程度的语义漂移。为避免两种视角的表示完全分离，本文在 $\mathbf{v}_o$ 与 $\mathbf{v}_r$ 之间引入均方误差（MSE）对齐约束：

$$\mathcal{L}_{\text{align}} = \frac{1}{h} \sum_{k=1}^h (\mathbf{v}_o^{(k)} - \mathbf{v}_r^{(k)})^2 \quad (20)$$

该方法在保留互补信息的同时限制两种视角偏移过大，以提高融合稳定性。

（3）联合优化目标

最终，DVIG-Ranker 的整体训练目标为

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{rank}} + \alpha \cdot \mathcal{L}_{\text{align}} \quad (21)$$

其中， α 为平衡系数，用于调节排序精度与语义一致性之间的权重。

通过上述设计，DVIG-Ranker 在学习需求指导下对双视角信息进行条件化、维度级融合，能够更准确地区分“主题相关”与“真正可回答当前问题”的证据。

3 实验

为验证本文所提出方法在继续教育知识学习场景中的有效性，本文从查询重写、重排序、端到端问答与部署效率四个层面开展实验。具体而言，实验旨在回答以下三个问题：

（1）学习需求感知查询重写是否能够稳定提升不同检索范式下的召回质量；

（2）双视角与学习需求门控机制是否能够进一步提升候选证据的排序质量；

（3）上述改进能否在统一约束下进一步转化为端到端答案质量的提升，并兼顾实际部署中的时延需求。

基于此，本文依次介绍数据集与统一评测协议、对比系统与评测指标，并在此基础上对实验结果进行系统分析。

3.1 数据集与实验环境

3.1.1 CASMOOC-LearnRAG 数据集

由于公开 RAG 数据集多面向开放域文本问答，缺少继续教育所需的学习需求标注、视频证据定位和课程级可追溯信息，本文依托 CASMOOC 平台构建 CASMOOC-LearnRAG 数据集^[1,2,4]，数据来源于 3000 余门专业课程视频，覆盖人工智能、电机电

子、自动化控制、新材料等领域。本文通过“语音识别—智能精修—人工校验”将课程内容转为可检索文本，并保留文本片段与原始视频的时间戳映射；知识库构建阶段采用固定长度切分与滑动窗口重叠相结合的策略形成证据块。

在此基础上，本文参考 Self-Instruct 的“生成—过滤—修正”思路构建评测样本^[52]。先从同一课程采样 2~5 个语义连续证据块作为上下文，并结合布鲁姆认知目标分类生成问题、答案和证据；再由第二大模型审核学习需求匹配、证据支持性和术语逻辑一致性；最后进行人工复核并修正提示模板与过滤规则。最终得到 18,000 条“问题—学习需求类型—匹配证据块—标准答案—视频定位信息”五元组样本，并按 Course-Level 方式划分为 14,400 条训练集、1,800 条验证集和 1,800 条测试集，同一课程不跨集合出现^[20,28,29]。表 2 给出了数据集的基本统计信息。

表 2 CASMOOC-LearnRAG 数据集统计信息

Table 2 Statistics of the CASMOOC-LearnRAG

dataset	
指标(Metrics)	数值(Values)
问题总数	18000
构建策略	每篇文档 6 个问题
支撑文档数	2~5
训练集	14400
验证集	1800
测试集	1800

3.1.2 实验环境

为保证比较公平，本文在所有端到端实验中采用统一评测协议，将性能差异尽量控制在是否引入学习需求感知查询重写与重排序机制这一核心变量上。

具体而言，所有系统使用同一 CASMOOC 知识库和相同切片策略(512 字符切分、100 字符重叠)；统一采用 BM25 与 Dense 组成的 Hybrid Retrieval，候选池规模固定为 Top-N=60；重排序后截取 Top-K $\in\{3,5,10\}$ 个证据块输入生成器；生成端统一使用 DeepSeekV3.2、相同提示模板与证据拼接格式；端到端评测均在 CASMOOC-LearnRAG 测试集上进行。

实验软硬件环境如表 3 所示。

表 3 实验环境

Table 3 Experimental environment

环境类型	配置参数
操作系统	Ubuntu 22.04.3 LTS
处 理 器	Intel(R) Xeon(R) Platinum 8255C
(CPU)	CPU @ 2.50GHz
图形处理器	NVIDIA RTX 4090
CUDA 版本	12.8
编程语言	Python 3.9
深度学习框	PyTorch 2.0.1
架	
模型加载与	Transformers 4.35.0, vLLM 0.2.1
加速	
向量检索库	FAISS 1.7.4, Elasticsearch 8.11

3.2对比系统与评测指标

为全面评估本文方法在查询重写、重排序及端到端闭环中的有效性，本文分别设计如下对比系统。

在查询重写实验中，通过 BM25、Dense 和 Hybrid 三种方式召回候选证据来比较下面三类方法^[11,18,20]：

(1) 原始问题：不进行任何查询重写，直接用于检索；

(2) 通用大模型直接重写：使用 DeepSeek、Qwen、Kimi 等通用大模型对原始问题进行改写；

(3) IQ-Rewriter：使用本文提出的学习需求感知查询重写模型，综合考虑性能与效率，本文选择并分别以 Qwen2.5-3B 和 Qwen2.5-7B 为基座进行评估。

在重排序实验中，首先分别通过 BM25、Dense 和 Hybrid 三种方式召回候选证据，再对比以下模型：

(1) No-rerank：直接使用召回阶段顺序，不进行重排序；

(2) bge-reranker-base/large (Zeroshot)：使用开源重排序器进行零样本评估；

(3) bge-reranker-base/large (Finetune)：在领域数据上微调后的重排序器；

(4) DVG-Ranker-Base/Large：本文提出的双视角与学习需求门控重排序模型。

在端到端实验中，构建两组开源基线系统与两组本文系统：

表 4 IQ-Rewriter 与不同基座 LLM 重写性能对比分析

Table 4 Comparison of query rewriting performance between IQ-Rewriter and different backbone LLMs						
问题设置	Rec@3(%)	MRR@3(%)	Rec@5(%)	MRR@5(%)	Rec@10(%)	MRR@10(%)
Retrieval Method: BM25						
原始问题	33.7	22.1	42.3	24.1	53.7	25.7
LLM 重写(DeepSeek)	27.7	18.5	37.9	20.8	48.6	22.2
LLM 重写(Qwen)	30.5	20.1	39.8	22.4	50.2	23.8
LLM 重写(Kimi)	29.8	19.8	39.2	22.0	49.8	23.5
IQ-Rewriter(Qwen2.5-3B)	33.7	23.4	42.4	25.5	51.2	26.7
IQ-Rewriter(Qwen2.5-7B)	34.2	23.9	43.1	26.2	52.8	27.4
Retrieval Method: Retrieval Method: Dense (moka-ai/m3e-base)						
原始问题	28.5	19.7	38.8	22.1	49.9	23.7
LLM 重写(DeepSeek)	31.2	21.9	40.0	23.9	51.1	25.4
LLM 重写(Qwen)	33.5	22.8	41.8	24.6	53.2	26.0
LLM 重写(Kimi)	33.1	22.5	41.5	24.4	52.8	25.8
IQ-Rewriter(Qwen2.5-3B)	35.0	23.2	42.4	25.0	53.5	26.5
IQ-Rewriter(Qwen2.5-7B)	36.8	24.5	44.5	26.2	55.2	27.8
Retrieval Method: Retrieval Method: Hybrid (BM25+Dense)						
原始问题	33.3	22.2	45.3	25.1	54.1	26.3
LLM 重写(DeepSeek)	32.3	22.8	43.0	25.3	53.0	26.6
LLM 重写(Qwen)	34.8	24.1	45.2	26.5	55.1	27.9
LLM 重写(Kimi)	34.5	23.9	44.8	26.2	54.8	27.6
IQ-Rewriter(Qwen2.5-3B)	37.1	25.8	46.1	27.9	56.0	29.2
IQ-Rewriter(Qwen2.5-7B)	39.2	27.0	48.5	29.1	58.5	30.8

(1) Baseline-Base：采用 moka-ai/m3e-base 作为稠密检索模型，采用 bge-reranker-base 作为重排序模型；

(2) Baseline-Large：采用 moka-ai/m3e-large 作为稠密检索模型，采用 bge-reranker-large 作为重排序模型；

(3) Ours-Base：在 Base 组相同召回底座下，将通用直接重写替换为 IQ-Rewriter(Qwen2.5-3B)，并将重排序器替换为 DVIG-Ranker-Base；

(4) Ours-Large：在 Large 组相同召回底座下，将通用直接重写替换为 IQ-Rewriter(Qwen2.5-7B)，并将重排序器替换为 DVIG-Ranker-Large。

通过上述设计，端到端对比能够更直接地反映：在保持召回框架、候选规模、生成器与提示模板一致的前提下，学习需求感知查询重写与双视角学习需求门控重排序是否能够为系统带来稳定增益。

为从检索链路质量和端到端回答质量

两个层面评估方法效果，本文采用 Recall@K、MRR@K、Token-F1 和 Rouge-L 四类指标^[11,29]，后续简称为 Rec、MRR、F1、R-L。

3.3实验结果与分析

3.3.1 查询重写实验

表 4 给出了不同查询重写方案在 BM25、Dense 和 Hybrid 三种检索范式下的结果。整体来看，通用大模型直接重写并未表现出稳定优势，而 IQ-Rewriter 在多数设置下取得更一致的提升，说明查询重写应面向下游检索目标进行优化。

在 BM25 设置下，通用大模型重写结果普遍低于原始问题，说明术语替换、条件弱化或表达迁移会破坏稀疏检索所依赖的关键词项。相比之下，IQ-Rewriter 更强调术语保真与条件补全，因此 MRR 表现更稳定。

在 Dense 与 Hybrid 设置下，IQ-Rewriter 优势更明显。以 Hybrid 为例，IQ-

Rewriter(Qwen2.5-7B) 的 Rec@3、Rec@5、Rec@10 分别达到 39.2、48.5 和 58.5，MRR@3、MRR@5、MRR@10 分别达到 27.0、29.1 和 30.8，均优于原始问题。

进一步比较 3B 与 7B 版本可见，二者均优于通用大模型直接重写，且 7B 整体更好，表明在学习需求信号与检索收益目标约束下，更强语义建模能力能够转化为检索增益。

因此，IQ-Rewriter 的有效性体现为围绕“是否更有利于召回正确证据”进行受控建模，而非追求表面流畅性。

3.3.2 重排序实验

表 5 展示了不同重排序方法在 BM25、Dense 和 Hybrid 三种召回底座上的表现。引入重排序后，Recall 与 MRR 均明显提升，说明候选集合中存在大量“主题相关但不直接解题”的片段，必须通过精排提高证据纯度。

与 No-rerank 相比，开源 bge-reranker 零样本版本已带来提升；经过领域数据微调后，base/large 版本进一步提高，说明本场景的证据判别标准不同于一般语义相关性。

DVIG-Ranker 在多数设置下进一步优于微调基线，尤其更稳定地提升 MRR。以 Hybrid 为例，DVIG-Ranker-Large 的 MRR@3、MRR@5 和 MRR@10 分别达到 57.9、60.1 和 60.8，均为该组最优，说明双视角建模与学习需求门控能将关键证据提前。

机制上，DVIG-Ranker 同时利用原始查询保留的真实约束与重写查询提供的规范

表达，并借助学习需求门控自适应融合两种视角，因此更容易区分“谈论同一主题”与“真正回答问题”。

总体而言，DVIG-Ranker 的增益来自对查询视角互补性与学习需求偏好的细粒度利用，更符合继续教育知识学习任务需求。

3.3.3 端到端结果

表 6 给出了不同系统在 Top-3、Top-5 和 Top-10 三种证据输入规模下的端到端结果。整体来看，本文方法在 Base 和 Large 组中均稳定优于对应基线。以 Top-5 为例，Ours-Base 的 MRR、Recall、Token-F1 和 Rouge-L 分别达到 58.1%、68.5%、51.5% 和 52.8%，高于 Baseline-Base；Ours-Large 分别达到 62.5%、71.3%、53.6% 和 54.4%，也明显优于 Baseline-Large。

由于各系统在知识库、召回框架、候选规模、生成模型和提示模板上保持一致，上述增益主要来自检索链路前后两端的协同优化。

不同 Top-K 设置显示，四组系统的 Token-F1 和 Rouge-L 基本在 Top-5 时最佳，说明证据数量并非越多越好：K=3 可能遗漏关键条件，K=10 则可能引入冗余片段并干扰生成。Top-5 在信息充分性和上下文纯度之间形成较好平衡。

从系统组成看，IQ-Rewriter 主要提高正确证据召回概率，DVIG-Ranker 主要把真正有用的证据排到更靠前位置，二者共同提升送入生成器的上下文质量。

表 5 不同规模底座模型下的重排序性能对比

Table 5 Comparison of reranking performance across backbone models of different sizes

模型设置	Rec@3(%)	MRR@3(%)	Rec@5(%)	MRR@5(%)	Rec@10(%)	MRR@10(%)
Retrieval Method: BM25						
No-rerank	33.7	23.4	42.4	25.5	51.2	26.7
bge-reranker-base(Zeroshot)	36.5	40.2	49.8	43.5	61.5	45.8
bge-reranker-large(Zeroshot)	38.2	42.5	51.5	45.9	63.8	48.2
bge-reranker-base(Finetune)	39.5	51.5	55.2	56.2	68.9	55.1
bge-reranker-large(Finetune)	41.2	53.8	57.1	58.0	70.5	57.2
DVIG-Ranker-Base	40.2	53.1	56.6	55.7	69.9	56.3
DVIG-Ranker-Large	42.1	55.2	58.5	57.8	71.8	58.5
Retrieval Method: Retrieval Method: Dense (moka-ai/m3e-base)						
No-rerank	31.2	21.9	40.0	23.9	51.1	25.4
bge-reranker-base(Zeroshot)	35.8	39.5	48.2	42.8	60.3	44.9

bge-reranker-large(Zeroshot)	37.5	41.2	50.1	44.6	62.5	46.8
bge-reranker-base(Finetune)	41.5	51.2	56.5	54.0	69.8	55.5
bge-reranker-large(Finetune)	42.8	53.5	58.2	56.2	71.2	57.5
DVIG-Ranker-Base	40.9	52.0	56.2	55.6	70.6	56.2
DVIG-Ranker-Large	42.5	54.1	58.0	57.5	72.1	58.3
Retrieval Method: Retrieval Method: Hybrid (BM25+Dense)						
No-rerank	32.3	22.8	43.0	25.3	53.0	26.6
bge-reranker-base(Zeroshot)	37.0	42.5	50.5	45.1	63.2	47.5
bge-reranker-large(Zeroshot)	39.1	44.8	52.8	47.2	65.1	49.5
bge-reranker-base(Finetune)	40.2	54.5	55.2	56.8	70.5	57.9
bge-reranker-large(Finetune)	42.5	56.5	57.1	58.9	72.0	59.5
DVIG-Ranker-Base	41.5	56.0	56.7	58.3	72.0	59.2
DVIG-Ranker-Large	43.8	57.9	58.9	60.1	73.5	60.8

表 6 端到端 RAG 系统总体效果对比

Table 6 Overall performance comparison of end-to-end RAG systems

系统配置	Top-3				Top-5				Top-10			
	MRR(%)	Rec(%)	F1(%)	R-L(%)	MRR(%)	Rec(%)	F1(%)	R-L(%)	MRR(%)	Rec(%)	F1(%)	R-L(%)
Baseline-Base	42.1	48.5	44.2	46.1	43.6	55.2	46.8	48.5	44.2	62.1	45.5	47.3
Ours-Base	56.4	58.4	49.3	50.4	58.1	68.5	51.5	52.8	58.5	73.2	50.8	52.1
Baseline-Large	45.3	52.1	46.5	48.0	46.9	58.8	48.9	50.1	47.5	65.4	47.6	49.2
Ours-Large	60.2	61.2	51.2	52.3	62.5	71.3	53.6	54.4	62.9	75.8	52.9	53.8

3.3.4 效率分析

查询重写模块的部署成本会影响继续教育平台的交互体验。本文进一步比较不同查询重写方案的平均推理时延，结果如表 7 所示。

结果显示，直接调用大模型逐条重写平均耗时为 2338 ms/条；采用本地批处理 IQ-Rewriter 后，batch=128 时 Qwen2.5-3B 约为 128 ms/条，Qwen2.5-7B 约为 240 ms/条，显著低于在线通用大模型调用。

因此，IQ-Rewriter 在保持检索收益的同时压缩了重写开销，为召回、重排序、证据拼接和答案生成预留了实时性空间。

结合结果可见，IQ-Rewriter 并非以速度换精度，而是在检索质量与部署效率之间取得较好平衡。

表 7 不同查询重写方案的平均推理耗时对比
(500 条问题)

Table 7 Comparison of average inference latency of different query rewriting methods (500 questions)

方案	设置	耗时
----	----	----

LLM 重写(Deepseek API)	batch=128	2338
IQ-Rewriter(RoBERTa+Qwen2.5-3B)	batch=128	~128
IQ-Rewriter(RoBERTa+Qwen2.5-7B)	batch=128	~240

4 结论

本文围绕继续教育知识学习场景下的 RAG 问题，提出学习需求感知的检索链路协同优化方法：在查询侧，IQ-Rewriter 通过学习需求约束与 DPO 检索收益对齐提升重写结果的检索适配性；在证据侧，DVIG-Ranker 通过原始查询与重写查询的双视角建模及学习需求门控融合，提高关键证据筛选精度与首命中位置。

实验结果表明，本文方法在查询重写、重排序和端到端问答三个层面均取得稳定收益。IQ-Rewriter(Qwen2.5-7B) 在 Hybrid 检索下取得最优 Rec@10 和 MRR@10 (58.5 和 30.8)；DVIG-Ranker-Large 在 Hybrid 设置下取得最优 MRR@3、MRR@5 和 MRR@10 (57.9、60.1 和 60.8)；端到端实验中，Ours-Large 在 Top-5 下的 MRR、

Recall、Token-F1 和 Rouge-L 分别达到 62.5、71.3、53.6 和 54.4，优于对应基线。

在实际应用上，本文将 IQ-Rewriter 与 DVIG-Ranker 集成到 CASMOOC 智能问答原型流程中，形成“问题输入—学习需求识别—查询重写—混合召回—双视角重排序—答案生成—证据与视频片段返回”的闭环。运行结果表明，该流程能够适应口语化提问、术语不规范和学习需求隐含等情况，减少“主题相关但不直接解题”片段进入生成上下文。

这说明，在强调答案可验证性、证据可追溯性和资源可回看性的继续教育场景中，RAG 性能瓶颈不仅在生成端，更在查询表达与证据筛选是否围绕学习目标协同优化。

本文仍存在局限：学习需求类别仍可细化，跨平台与跨领域泛化能力也有待验证。未来可进一步构建更动态的学习需求体系，探索长视频与多模态知识资源的统一证据建模，并结合引用对齐、证据压缩和可解释回答策略，构建更完整的可信 RAG 系统。

利益冲突声明

所有作者声明不存在利益冲突关系。

参考文献

- [1] 赵以霞, 金昆, 郑晓欢, 等. 2018 年中国科学院继续教育网科研人员在线学习数据集[J]. 中国科学数据:中英文网络版, 2019,4(3):162-170.
- [2] 赵以霞, 金昆, 金琰. 网络环境下科研人员继续教育内容研究——以中国科学院继续教育网资源为例[J]. 科研信息化技术与应用, 2018, 9(6): 8.
- [3] 赵以霞, 熊英, 王闰强, 等. 学习技术演进视角下的大型组织机构学习管理系统建设与实践研究[J]. 数据与计算发展前沿, 2025, 7(3): 94-110.
- [4] 张奇, 熊英, 张思思, 等. 中科院继续教育平台使用现状的分析[J]. 高等工程教育研究, 2021(1): 72-80.
- [5] 金昆, 赵以霞. 终身学习环境下的科研机构在线教育模式研究——以中国科学院继续教育网为例[J]. 继续教育, 2017(12): 4.
- [6] LAAL M, SALAMATI P. Lifelong learning; why do we need it?[J]. Procedia-Social and Behavioral Sciences, 2012, 31: 399-403.
- [7] KASNECI E, SESSLER K, KÜCHEMANN S, et al. ChatGPT for good? On opportunities and challenges of large language models for education[J]. Learning and Individual Differences, 2023, 103: 102274.
- [8] XU H, GAN W, QI Z, et al. Large language models for education: A survey[J]. arXiv preprint arXiv:2405.13001, 2024.
- [9] WANG S, XU T, LI H, et al. Large language models for education: A survey and outlook[J]. IEEE Signal Processing Magazine, 2026, 42(6): 51-63.
- [10] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-augmented generation for knowledge-intensive nlp tasks[J]. Advances in neural information processing systems, 2020, 33: 9459-9474.
- [11] GAO Y, XIONG Y, GAO X, et al. Retrieval-augmented generation for large language models: A survey[J]. arXiv preprint arXiv:2312.10997, 2023, 2(1): 32.
- [12] HUANG L, YU W, MA W, et al. A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions[J]. ACM Transactions on Information Systems, 2025, 43(2): 1-55.
- [13] MUNAYE Y Y, ADMASS W, BELAYNEH Y, et al. ChatGPT in education: A systematic review on opportunities, challenges, and future directions[J]. Algorithms, 2025, 18(6): 352.
- [14] BAIG M I, YADEGARIDEHKORDI E. ChatGPT in the higher education: A systematic literature review and research challenges[J]. International journal of educational research, 2024, 127: 102411.
- [15] ACHIAM J, ADLER S, AGARWAL S, et al. Gpt-4 technical report[J]. arXiv preprint arXiv:2303.08774, 2023.
- [16] HUI B, YANG J, CUI Z, et al. Qwen2.5-coder technical report[J]. arXiv preprint

- arXiv:2409.12186, 2024.
- [17] ASAI A, WU Z, WANG Y, et al. Self-rag: Learning to retrieve, generate, and critique through self-reflection[C]//The Twelfth International Conference on Learning Representations. 2023.
- [18] LI Z, WANG Z, WANG W, et al. Retrieval-augmented generation for educational application: A systematic survey[J]. Computers and Education: Artificial Intelligence, 2025, 8: 100417.
- [19] SARTHI P, ABDULLAH S, TULI A, et al. Raptor: Recursive abstractive processing for tree-organized retrieval[C]//The Twelfth International Conference on Learning Representations. 2024.
- [20] WANG X, WANG Z, GAO X, et al. Searching for best practices in retrieval-augmented generation[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. 2024: 17716-17736.
- [21] RACKAUCKAS Z. Rag-fusion: a new take on retrieval-augmented generation[J]. arXiv preprint arXiv:2402.03367, 2024.
- [22] ZHANG N, CHOUBEY P K, FABBRI A, et al. SiReRAG: Indexing Similar and Related Information for Multihop Reasoning[J].
- [23] MA X, GONG Y, HE P, et al. Query rewriting in retrieval-augmented large language models[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. 2023: 5303-5315.
- [24] VOSKARIDES N, LI D, REN P, et al. Query resolution for conversational search with limited supervision[C]//Proceedings of the 43rd International ACM SIGIR conference on research and development in Information Retrieval. 2020: 921-930.
- [25] HAN H, WANG Y, SHOMER H, et al. Retrieval-augmented generation with graphs (graphrag)[J]. arXiv preprint arXiv:2501.00309, 2024.
- [26] JIANG Z, XU F F, GAO L, et al. Active retrieval augmented generation[C]//Proceedings of the 2023 conference on empirical methods in natural language processing. 2023: 7969-7992.
- [27] LI Z, WANG J, MAO H, et al. DMQR-RAG: Diverse Multi-Query Rewriting in Retrieval-Augmented Generation[J]. 2024.
- [28] YAN S Q, GU J C, ZHU Y, et al. Corrective retrieval augmented generation[J]. 2024.
- [29] SALEMI A, ZAMANI H. Evaluating retrieval quality in retrieval-augmented generation[C]//Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2024: 2395-2400.
- [30] CARPINETO C, ROMANO G. A survey of automatic query expansion in information retrieval[J]. Acm Computing Surveys (CSUR), 2012, 44(1): 1-50.
- [31] WANG L, YANG N, WEI F. Query2doc: Query expansion with large language models[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. 2023: 9414-9423.
- [32] GAO L, MA X, LIN J, et al. Precise zero-shot dense retrieval without relevance labels[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2023: 1762-1777.
- [33] KARPUKHIN V, OGUZ B, MIN S, et al. Dense passage retrieval for open-domain question answering[C]//Proceedings of the 2020 conference on empirical methods in natural language processing (EMNLP). 2020: 6769-6781.
- [34] ROBERTSON S, ZARAGOZA H. The probabilistic relevance framework: BM25 and beyond: 卷 4[M]. Now Publishers Inc, 2009.
- [35] CARBONELL J, GOLDSTEIN J. The use of MMR, diversity-based reranking for

- reordering documents and producing summaries[C]//Proceedings of the 21st annual international ACM SIGIR conference on Research and development in information retrieval. 1998: 335-336.
- [36] CORMACK G V, CLARKE C L, BUETTCHER S. Reciprocal rank fusion outperforms condorcet and individual rank learning methods[C]//Proceedings of the 32nd international ACM SIGIR conference on Research and development in information retrieval. 2009: 758-759.
- [37] NOGUEIRA R, JIANG Z, PRADEEP R, et al. Document ranking with a pretrained sequence-to-sequence model[C]//Findings of the association for computational linguistics: EMNLP 2020. 2020: 708-718.
- [38] YATES A, NOGUEIRA R, LIN J. Pretrained transformers for text ranking: BERT and beyond[C]//Proceedings of the 14th ACM International Conference on web search and data mining. 2021: 1154-1156.
- [39] NOGUEIRA R, CHO K. Passage Re-ranking with BERT[J]. arXiv preprint arXiv:1901.04085, 2019.
- [40] CHEN J, XIAO S, ZHANG P, et al. Bge m3-embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation[J]. arXiv preprint arXiv:2402.03216, 2024, 4(5).
- [41] WANG Yuxin, SUN Qingxuan, HE Sicheng. M3E: Moka Massive Mixed Embedding Model [CP/OL]. Hugging Face, 2023.[2026-02-15].<https://huggingface.co/moka-ai/m3e-base>.
- [42] FRIEL R, BELYI M, SANYAL A. Ragbench: Explainable benchmark for retrieval-augmented generation systems[J]. arXiv preprint arXiv:2407.11005, 2024.
- [43] BLOOM B S, ENGELHART M D, FURST E J, et al. Taxonomy of educational objectives: The classification of educational goals. Handbook 1: Cognitive domain[M]. Longman New York, 1956.
- [44] CONKLIN J. A taxonomy for learning, teaching, and assessing: A revision of Bloom's taxonomy of educational objectives complete edition[M]. JSTOR, 2005.
- [45] DONG G, YUAN H, LU K, et al. How abilities in large language models are affected by supervised fine-tuning data composition[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2024: 177-198.
- [46] ZHANG H, WU Y, LI D, et al. Balancing speciality and versatility: a coarse to fine framework for supervised fine-tuning large language model[C]//Findings of the Association for Computational Linguistics: ACL 2024. 2024: 7467-7509.
- [47] RAFAILOV R, SHARMA A, MITCHELL E, et al. Direct preference optimization: Your language model is secretly a reward model[J]. Advances in neural information processing systems, 2023, 36: 53728-53741.
- [48] RUDER S. An overview of multi-task learning in deep neural networks[J]. arXiv preprint arXiv:1706.05098, 2017.
- [49] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [50] OORD A van den, LI Y, VINYALS O. Representation learning with contrastive predictive coding[J]. arXiv preprint arXiv:1807.03748, 2018.
- [51] BERTRAM T, FÜRNKRANZ J, MÜLLER M. Contrastive Learning of Preferences with a Contextual InfoNCE Loss[EB/OL]. arXiv, 2024.[2026-04-13]. <http://arxiv.org/abs/2407.05898>.
- [52] WANG Y, KORDI Y, MISHRA S, et al. Self-instruct: Aligning language models with self-generated

instructions[C]//Proceedings of the 61st annual meeting of the association for computational linguistics (volume 1: long papers). 2023: 13484-13508.

收稿日期： 2026 年 4 月 21 日

作者简介：

赵贵龙，中国科学院计算机网络信息中心，硕士研究生，主要研究方向为检索增强生成、自然语言处理。

本文中负责提出模型框架，设计实验，论文撰写等。

ZHAO Guilong, a Master's student at the Computer Network Information Center, Chinese Academy of Sciences, specializes in Retrieval-Augmented Generation and Natural Language Processing.

In this paper, he was responsible for proposing the model framework, designing the experiments, and drafting the manuscript. E-mail: glzhao@cnic.cn



何洪波，中国科学院计算机网络信息中心，高级工程师，硕士生导师，主要研究方向为新媒体技术应用、互联网数据挖掘和信息推荐。

本文中负责思路解析和把握文章逻辑与框架，写作指导，论文修订等。

HE Hongbo is a senior engineer and master's supervisor at the Computer Network Information Center, Chinese Academy of Sciences. His primary research interests include new media technology applications, internet data mining, and information recommendation.

In this paper, he is responsible for analyzing the core concepts, designing its logical framework, providing writing guidance, revising the paper.

E-mail: hhb@cnic.cn

