

Pandas 数据处理与清洗实战

Python 数据分析 · 第 2 讲

慧编学伴 · Python 数据分析课程资料

学习目标

- 理解 Series 与 DataFrame 的结构与索引机制
- 掌握 CSV 读写、缺失值处理、重复值与类型转换
- 熟练使用 groupby、pivot_table、merge 完成聚合与关联
- 完成电商订单样例的清洗与汇总练习

1. Pandas 在分析流程中的位置

典型流程：数据获取 → 清洗 → 转换 → 聚合 → 可视化 → 结论。Pandas 负责中间 80% 的结构化表格操作，是工业界事实标准。

2. 数据结构

Series：带标签的一维数组，可理解为 DataFrame 的一列。

DataFrame：二维表格，行索引 Index、列名 columns、值 values (ndarray)。

loc 按标签选取，iloc 按位置选取；避免链式赋值警告 (SettingWithCopyWarning)。

3. 数据清洗清单

- 缺失值：isna、fillna、dropna；策略有均值/中位数/众数填充或插值
- 重复值：duplicated、drop_duplicates
- 类型：astype、pd.to_datetime、pd.to_numeric(errors='coerce')
- 异常值：IQR 法则或业务规则过滤

4. 分组与透视

groupby('col').agg({'amount': 'sum', 'order_id': 'count'})

pivot_table(index='region', columns='month', values='sales', aggfunc='sum')

merge / concat 实现多表连接与纵向堆叠

代码示例

```
import pandas as pd

df = pd.read_csv('orders.csv', parse_dates=['order_time'])
# ■■■■■■
df['amount'] = pd.to_numeric(df['amount'], errors='coerce')
df['amount'] = df['amount'].fillna(df['amount'].median())

# ■■
df = df.drop_duplicates(subset=['order_id'])

# ■■■■■■
df['month'] = df['order_time'].dt.to_period('M').astype(str)
```

```
# ■■■■■■■■■■
summary = (
    df.groupby(['region', 'month'], as_index=False)
        .agg(total_amount=('amount', 'sum'), order_cnt=('order_id', 'count'))
)

# ■■■
pivot = df.pivot_table(
    index='region', columns='month', values='amount', aggfunc='sum', fill_value=0
)
print(summary.head())
print(pivot)
```

练习题

1. 读取 CSV 后统计每列缺失率，并删除缺失超过 50% 的列。
2. 将 user_id 转为 category 类型，比较内存占用变化 (memory_usage) 。
3. 按 product_category 分组，计算单价 amount/quantity 的均值与中位数。
4. 使用 merge 将订单表与用户表按 user_id 连接，输出含用户城市的汇总。
5. 对重复 order_id 保留 order_time 最新的一条记录。

参考资料

- 北京理工大学《Python 数据分析与展示》MOOC (NumPy / Pandas / Matplotlib 体系)
- 博雅数智《Python 数据分析》课程大纲 (NumPy→Pandas→可视化)
- LeeMeng《資料科學家的 pandas 實戰手冊》(DataFrame 清洗与汇总)
- pandas 官方文档: <https://pandas.pydata.org/docs/>
- NumPy 官方文档: <https://numpy.org/doc/>